



Studium Magisterskie

Kierunek: Analiza danych - big data

Imię i nazwisko autora:

Vitali Vitkouski

Nr albumu: 102411

Zastosowanie analizy sentymentu na przykładzie opisów aukcji na platformie Allegro

Praca magisterska

pod kierunkiem naukowym

dr. Zbigniewa Gontara

Instytut Informatyki i Gospodarki
Cyfrowej

Warszawa 2021

Spis treści

Wstęp.....	4
Rozdział I. Analiza sentymentu jako metoda przetwarzania języka naturalnego	6
1.1. Definiowanie pojęcia Big Data.....	6
1.2. Rozwój Big Data.....	7
1.3. Narzędzia i technologie Big Data typu open source	9
1.4. Kluczowe zastosowania Big Data.....	14
1.5. Rozwój przetwarzania języka naturalnego	17
1.6. Przebieg analizy sentymentu	21
1.6.1. Podejście leksykalne.....	23
1.6.2. Uczenie maszynowe	25
1.6.3. Podejście hybrydowe	27
Rozdział II. Przygotowanie do analizy regresji	28
2.1. Budowanie słownika.....	28
2.2. Wydobywanie danych z Allegro.pl.....	30
2.2.1. Przygotowanie do wydobywania danych	31
2.2.2. Wybór kategorii.....	32
2.2.3. Wydobywanie linków do poszczególnych ofert w wybranej kategorii.....	35
2.2.4. Wydobywanie opisów, cen, liczb kupujących oraz zakupionych jednostek towarów na poszczególnych ofertach.....	38
2.3. Analiza wydźwięku emocjonalnego opisów ofert	41
Rozdział III. Analiza regresji na danych z analizy wydźwięku emocjonalnego	44
3.1. Opis zmiennych	44
3.2. Przygotowanie zmiennych do regresji	48
3.3. Analiza regresji	50
3.4. Sprawdzenie założeń regresji liniowej	58
3.5. Interpretacja wyników modelu 7	60
Zakończenie.....	62
Bibliografia.....	63
Spis tabel i rysunków.....	70
Streszczenie	71

Wstęp

Niniejsza praca została napisana na kierunku analiza danych – big data, dlatego wybrano temat związany z analizą danych, a studia na uczelni ekonomicznej zakładają, że temat powinien mieć wartość ekonomiczną i biznesową. Analiza sentymentu jest ciekawa sama w sobie, a w połączeniu z danymi pochodzącymi z platformy handlowej może dawać niespodziewane wyniki. W związku z tym, że w ciągu ostatnich kilku lat na rynku nieustannie rozwijają się technologie e-biznesu, popyt na badania tej branży rośnie, co prowadzi do powstawania coraz bardziej zaawansowanych dziedzin pokrewnych. Dziedziny te pozwalają przeprowadzać różnorodne analizy, na podstawie których wdrażane są efektywniejsze rozwiązania służące do pozytywnego doświadczenia klientów oraz generowania większego zysku.

Przedmiotem badania pracy jest związek pomiędzy elementami oferty a wartością sprzedaży na danej ofercie. W tym celu z platformy handlowej Allegro zostały wydobyte dane za pomocą samodzielnie napisanego programu. Ponieważ proces ten był rozłożony w czasie, poszczególne obserwacje mogą pochodzić z różnych momentów w czasie. Na danych przeprowadzono analizę regresji, która była możliwa po wcześniejszej analizie wydźwięku emocjonalnego metodą słownikową.

Zanim przystąpiono do analizy właściwej, została postawiona hipoteza badawcza. Ponieważ dane dotyczą sprzedaży towarów na internetowej platformie handlowej, najwyższą wartość dodaną ma hipoteza związana z wartością sprzedaży. W związku z tym, że praca dotyczy analizy sentymentu, wybrano wpływ wydźwięku emocjonalnego opisu oferty na wartość sprzedaży tej oferty. W hipotezie zerowej zakłada się, że pozytywny wydźwięk słów w opisie oferty *ma dodatni wpływ* na wartość sprzedaży. Hipotezy alternatywne:

- H1: pozytywny wydźwięk słów w opisie oferty *ma ujemny wpływ* na wartość sprzedaży
- H2: pozytywny wydźwięk słów w opisie oferty *nie ma wpływu* na wartość sprzedaży

W literaturze nie znaleziono przykładów badania takiej hipotezy, natomiast wiele badań wskazuje na wpływ opinii klientów, recenzji, reklamy w serwisach społecznościowych na

wartość sprzedaży^{1, 2, 3}. Na podstawie tego można założyć, że opis produktu na stronie oferty jest zarówno opinią, recenzją, jak i swojego rodzaju reklamą. Z drugiej strony, z doświadczenia autora opisy nacechowane pozytywnymi emocjami pobudza do zakupu, jednak nadmiar może zniechęcić część potencjalnych klientów.

W rozdziale I opisana jest zmieniająca się wraz z upływem czasu definicja danych Big Data. Poza definicją przedstawiono również rozwój tego zjawiska oraz narzędzia stosowane do przetwarzania takich danych. Także wymieniono problemy, do rozwiązania których stosowane są dane Big Data. Zaprezentowano historię powstania przetwarzania języka naturalnego, a następnie opisano proces analizy sentymentu oraz różne podejścia w zależności od danych i celów badań.

Rozdział II przedstawia proces przygotowania danych do analizy regresji. Najpierw opisany został przebieg działań podjętych do powstania słownika. Następnie pokazane są działania podjęte do wydobywania danych ze witryny internetowej Allegro. Na końcu rozdziału przeprowadzona została analiza wydźwięku emocjonalnego tekstów wydobytych podczas ekstrakcji danych ze stron.

W rozdziale III przedstawiono przeprowadzoną analizę regresji. Najpierw opisane zostały zmienne ze zbioru danych, a następnie sposób przygotowania tych danych do regresji. Zaprezentowano również samą regresję, a także wyniki tej analizy.

Do przeprowadzenia badania wykorzystano najpierw analizę wydźwięku emocjonalnego metodą słownikową z podejścia leksykalnego w ramach przetwarzania języka naturalnego. Wyniki tej analizy posłużyły do przeprowadzenia analizy regresji metodą najmniejszych kwadratów.

¹ Cheng L., Huang C., Exploring contextual factors from consumer reviews affecting movie sales: an opinion mining approach, *Electronic Commerce Research*, 2019, s.22-23

² Babić Rosario A., Sotgiu F., De Valck K., Bijmolt T., The Effect of Electronic Word of Mouth on Sales: A Meta-Analytic Review of Platform, Product, and Metric Factors, *Journal of Marketing Research*, vol. 53, nr 3, 2016, s.297–318

³ Wan F., Ren F., The effect of firm marketing content on product sales: Evidence from a mobile social media platform, *Journal of Electronic Commerce Research*, nr 18, 2017, s.288-302

Rozdział I. Analiza sentymentu jako metoda przetwarzania języka naturalnego

1.1. Definiowanie pojęcia Big Data

International Data Corporation (IDC) opublikowała swoje coroczne prognozy DataSphere i StorageSphere, które mierzą ilość danych tworzonych, skonsumowanych oraz przechowywanych każdego roku na świecie. Zgodnie z ustaleniami IDC, w 2020 roku utworzono lub powielono 64,2 ZB (zettabajtów, 10^{21} bajtów) danych ze względu na przejście wielu osób z nauki oraz pracy stacjonarnej na formę zdalną. Jednak mniej niż 2% tych nowych danych zostało zapisanych i zachowanych do 2021 r., dlatego że pozostałe 98% wynikają głównie z konsumowania albo tymczasowego przechowywania, a następnie nadpisywania przez nowe dane. Według Dave'a Reinsela, starszego wiceprezesa IDC Global DataSphere, ilość danych cyfrowych utworzonych w ciągu najbliższych pięciu lat będzie ponad dwukrotnie większa od ilości danych utworzonych od czasu pojawienia się nośników cyfrowych.⁴

Big Data (BD) to jest pojęcie abstrakcyjne i obecnie nie posiada jedynej definicji, ponieważ badacze i organizacje z różnych dziedzin wprowadzają własne definicje. Ogólnie rzecz biorąc, oznacza zbiory danych, które nie mogą być uzyskane, zarządzane i przetwarzane za pomocą tradycyjnych narzędzi informatycznych i oprogramowania w relatywnie krótkim czasie. Tak zdefiniowano BD w 2010 r. przez Apache Hadoop. Poniższe definicje mogą pomóc lepiej zrozumieć społeczne, ekonomiczne i technologiczne aspekty Big Data.⁵

Na podstawie powyższej definicji globalna agencja konsultingowa McKinsey & Company w 2011 r. wprowadziła własną, dodając niemożliwość przetwarzania i zarządzania przez klasyczne oprogramowanie bazodanowe. Po pierwsze, zbiory danych, które są zgodne ze definicją Big Data, zmieniają się i mogą rosnąć z czasem lub wraz z postępem technologicznym. Po drugie, zbiory danych zarządzane przez narzędzia zaimplementowane na podstawie różnych standardów BD mogą różnić się od siebie. Z danej definicji wynika, że wielkość zbioru danych nie jest jedynym kryterium. Rosnące wolumeny zbiorów danych i niemożliwość zarządzania nimi za pomocą tradycyjnych technologii obsługi baz danych to są kolejne dwie kluczowe cechy.⁶

⁴ International Data Corporation, Data Creation and Replication Will Grow at a Faster Rate than Installed Storage Capacity, According to the IDC Global DataSphere and StorageSphere Forecasts, 2021, <https://www.idc.com/getdoc.jsp?containerId=prUS47560321> [Dostęp: lipiec 2021]

⁵ Chen M., Mao S., Liu Y., Big Data: A Survey. Mobile Networks and Applications nr 19, 2014, s.173

⁶ Manyika J. et al., Big data: the next frontier for innovation, competition, and productivity, McKinsey Global Institute, 2011, s.2

W 2001 roku analityk META Doug Laney zdefiniował w raporcie z badań wyzwania i szanse, jakie niesie za sobą wzrost ilości danych w modelu 3V, tj. wzrost wolumenu (ang. volume), prędkości (ang. velocity) i różnorodności (ang. variety). W modelu 3V wolumen oznacza, że wraz z generowaniem i gromadzeniem danych skala danych staje się coraz większa. Prędkość oznacza, że dane powinny być przetwarzane szybko i terminowo, aby maksymalnie wykorzystać wartość komercyjną danych. Różnorodność wskazuje na różne typy danych, które obejmują dane częściowo ustrukturyzowane i nieustrukturyzowane, takie jak audio, wideo, strony internetowe i tekst, a także tradycyjne dane strukturalne.⁷

W 2011 r. raport IDC podał następującą definicję: technologie Big Data opisują nową generację technologii i architektur, zaprojektowanych w celu ekonomicznego wydobywania wartości z bardzo dużych wolumenów różnorodnych danych poprzez umożliwienie szybkiego zdobywania, odkrywania i analizowania⁸. Można to podsumować jako model 4V, tj. wolumen (duży wolumen), różnorodność (różne typy danych), prędkość (szybkie generowanie) i wartość (ang. value, ogromna wartość o bardzo niskiej gęstości). Taka definicja była powszechnie uznawana, ponieważ podkreśla znaczenie i potrzebę BD, czyli potrzebę odkrywania ogromnych ukrytych wartości. Model 4V wskazuje na najbardziej krytyczny problem w Big Data, jakim jest sposób odnajdywania wartości ze zbiorów danych o ogromnej skali, różnych typach i szybkim generowaniu⁹.

1.2. Rozwój Big Data

Pod koniec lat 70. XX w. pojawiła się koncepcja maszyny bazodanowej (ang. database machine), która jest technologią używaną specjalnie do przechowywania i analizy danych. Wraz ze wzrostem ilości danych pojemność pamięci i zdolność przetwórcza pojedynczego systemu komputerowego typu mainframe stała się niewystarczająca. W latach 80. XX w. zaproponowano architekturę typu share nothing, aby sprostać wymaganiom rosnącego wolumenu danych¹⁰. Taki typ architektury systemu opiera się na wykorzystaniu klastra, a każda maszyna ma swój własny procesor, pamięć i dysk. System Teradata był pierwszym udanym komercyjnym systemem równoległej bazy danych. Taka baza danych stała się ostatnio bardzo

⁷ Laney D., 3D data management: controlling data volume, velocity and variety, META Group Research Note, 2001, s.2-3

⁸ Gantz J., Reinsel D., Extracting value from chaos, IDC iView, 2011, s.5

⁹ Mayer-Schönberger V., Cukier K., Big Data: A Revolution that Will Transform how We Live, Work, and Think, 2013, s.4

¹⁰ DeWitt D., Gray J., Parallel database systems: the future of high performance database systems. Communications of the ACM, vol. 35, nr 6, 1992, s.87–88

popularna. 2 czerwca 1986 r. miało miejsce przełomowe wydarzenie, kiedy firma Teradata dostarczyła firmie Kmart pierwszy równoległy system baz danych o pojemności 1 TB (terabajt, 10¹² bajtów), aby pomóc w rozbudowie hurtowni danych¹¹. Pod koniec lat 90. XX w. zalety równoległej bazy danych zostały powszechnie uznane w dziedzinie baz danych.

Wraz z rozwojem serwisów internetowych szybko rosło indeksowanie i wyszukiwanie treści, dlatego obsługa dużych zbiorów danych stała się wyzwaniem dla firm tworzących wyszukiwarki internetowe. Korporacja Google stworzyła model numeryczny GFS¹² (ang. Global Forecast System, krótkoterminowy globalny model numeryczny) i platformę MapReduce¹³, aby sprostać wyzwaniom związanym z zarządzaniem danymi i analizą w skali internetowej. Ponadto, treści generowane przez użytkowników, czujniki i inne rozpowszechnione źródła danych również napędzały przepływy danych, co wymagało fundamentalnej zmiany w architekturze obliczeniowej i mechanizmie przetwarzania danych na dużą skalę. W styczniu 2007 roku pionier oprogramowania bazodanowego Jim Gray nazwał taką transformację czwartym paradygmatem (ang. The Fourth Paradigm)¹⁴. Uważał również, że jedynym sposobem radzenia sobie z takim paradygmatem jest opracowanie nowej generacji narzędzi komputerowych do zarządzania, wizualizacji i analizy ogromnych danych. W czerwcu 2011 r. EMC Corporation wraz z IDC opublikowała raport badawczy pt. „Extracting Values from Chaos”¹⁵, który po raz pierwszy przedstawił pojęcie i potencjał BD. Ten raport wywołał duże zainteresowanie zarówno w branży, jak i środowisku akademickim.

Od 2005 r. IBM zainwestował 24 mld dolarów amerykańskich w 30 przejąć przedsiębiorstw związanych z Big Data, przy czym dochód wyniósł 20 mld w 2015¹⁶. W środowisku akademickim BD również się znalazło w centrum uwagi. W 2008 roku czasopismo naukowe Nature opublikowało specjalne wydanie dotyczące BD¹⁷. W 2011 r. czasopismo Science także wypuściło specjalny numer poświęcony kluczowym technologiom przetwarzania

¹¹ Walter T., Teradata past, present, and future, UCI ISG lecture series on scalable data management, 2009, s.2

¹² Ghemawat S., Gobioff H., Leung S., The Google file system, ACM SIGOPS Operating Systems Review, vol. 37, nr 5, 2003, s.34

¹³ Dean J., Ghemawat S., MapReduce: simplified data processing on large clusters, Communications of the ACM, vol. 51, nr 1, 2008, s.108

¹⁴ Hey T., Tansley S., Tolle K., The Fourth Paradigm: Data-Intensive Scientific Discovery, Microsoft Research, 2009, s.165–166

¹⁵ Gantz J., Reinsel D., Extracting value from chaos, IDC iView, 2011, s.7

¹⁶ Versace C., Talking Big Data And Analytics With IBM, Forbes, 2014, <https://www.forbes.com/sites/chrisversace/2014/04/01/talking-big-data-and-analytics-with-ibm/> [Dostęp: lipiec 2021]

¹⁷ Nature, Science in the petabyte era, vol. 455, nr 7209, 2008, <https://www.nature.com/nature/volumes/455/issues/7209> [Dostęp: lipiec 2021]

danych w Big Data¹⁸. W 2012 r. czasopismo News Europejskiego Konsorcjum Badawczego ds. Informatyki i Matematyki (ERCIM) opublikowało specjalne wydanie dotyczące BD¹⁹. Na początku 2012 r. raport pt. „Big Data, Big Impact: New Possibilities for International Development” zaprezentowany na Światowym Forum Ekonomicznym w Davosie, Szwajcaria ogłosił, że BD stało się nowym rodzajem aktywów gospodarczych, podobnie jak waluta czy złoto²⁰.

Rządy państw również przywiązują dużą wagę do Big Data. W 2012 r. administracja Obamy w Stanach Zjednoczonych ogłosiła zainwestowanie 200 mln dolarów amerykańskich w uruchomienie Planu badań i rozwoju BD²¹, który był drugą dużą inicjatywą rozwoju naukowego i technologicznego po inicjatywie Autostrada informacyjna z 1993 r²². W tym samym roku Organizacja Narodów Zjednoczonych opublikowała raport, w którym podsumowano, w jaki sposób rządy wykorzystywały duże zbiory danych, aby lepiej służyć i chronić swoich obywateli²³.

1.3. Narzędzia i technologie Big Data typu open source

Tabela 1 przedstawia otwarte rozwiązania do analizy danych Big Data. Znajdują się w niej wybrane najważniejsze technologie i oprogramowanie typu open source (o otwartym kodzie źródłowym), które pozwalają zajmować się analizą danych BD bez poniesienia wysokich kosztów, co pozwala na obniżenie progu wejścia.

¹⁸ Science, Dealing with Data, vol. 331, nr 6018, 2011, <https://science.sciencemag.org/content/331/6018> [Dostęp: lipiec 2021]

¹⁹ ERCIM News, Special theme: Big Data, nr 89, 2012, <http://www.planet-data.eu/publications/ercim-news-special-theme-big-data.html> [Dostęp: lipiec 2021]

²⁰ Vital Wave Consulting, Big Data, Big Impact: New Possibilities for International Development, World Economic Forum, 2012, http://www3.weforum.org/docs/WEF_TC_MFS_BigDataBigImpact_Briefing_2012.pdf [Dostęp: lipiec 2021]

²¹ Weiss R., Zgorski L., PRESS RELEASE: Obama Administration Unveils "Big Data" Initiative: Announces \$200 Million in New R&D Investments, The White House, 2012, <https://obamawhitehouse.archives.gov/the-press-office/2015/11/19/release-obama-administration-unveils-big-data-initiative-announces-200> [Dostęp: lipiec 2021]

²² Chen M., Mao S., Liu Y., op.cit., s.175

²³ UN Global Pulse, Big Data for Development: Challenges and Opportunities, 2012, <https://www.unglobalpulse.org/wp-content/uploads/2012/05/BigDataforDevelopment-UNGlobalPulseMay2012.pdf> [Dostęp: lipiec 2021]

Tabela 1. Otwarte rozwiązania do analizy danych Big Data

Nazwa	Zastosowanie	Cechy i funkcjonalność
Hadoop ²⁴	Oprogramowanie do przetwarzania Big Data.	Skalowalność, niezawodność, odporność na błędy, bycie systemem wysokiej niezawodności, lokalne przetwarzanie i przechowywanie, przetwarzanie rozproszone i równoległe oraz opłacalność ekonomiczna. Wykorzystuje prosty model programowania do przetwarzania dużych zbiorów danych w klastrach komputerowych. Został opracowany w celu skalowania od pojedynczego serwera do tysięcy maszyn i zapewnia kolokację (wzajemne udostępnianie mocy obliczeniowej pomiędzy maszynami) pamięci masowej i obliczeń. Jego biblioteka została zaprojektowana w taki sposób, aby mogła samodzielnie identyfikować awarie i zapewniać mechanizm odzyskiwania. System plików Hadoop (HDFS)²⁵ jest ważnym składnikiem Hadoop i ma architekturę główny-podrzędny (ang. master-slave). Składa się z dwóch komponentów – NameNode (węzeł nazwy) i DataNode (węzeł danych), może przetwarzać obszerne zbiory danych i został zaprojektowany z myślą o tanim systemie. Rozproszony system plików zapewnia wysoką przepustowość. Głównym celem HDFS jest zapewnienie następujących funkcji: zwiększenie przepustowości poprzez zmniejszenie przeciążenia sieci, wykrywanie i izolacja błędów, dostęp do dużych zbiorów danych, dostęp do danych przesyłanych strumieniowo, prosty model spójności oraz przenośność między różnymi urządzeniami i oprogramowaniem.
MapReduce	Platforma do przetwarzania	Składa się z dwóch podstawowych elementów: fazy mapowania (ang. map phase) i fazy redukcji (ang. reduce

²⁴ Apache Software Foundation, HDFS Architecture, 2021, <https://hadoop.apache.org/docs/r3.3.1/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html> [Dostęp: lipiec 2021]

²⁵ Ibidem

	ogromnej ilości danych.	phase). Obciążenie jest dzielone na mniejsze obciążenia w fazie mapowania, a dane wyjściowe w postaci listy par klucz-wartość (ang. key-value) są przekazywane do fazy redukcji, która analizuje i redukuje wyniki w celu uzyskania ostatecznego wyniku. Także dzieli zbiór danych na części, które będą równolegle przetwarzane w fazie mapowania. Dane wyjściowe programu mapującego są sortowane według struktury i dalej wysyłane do fazy redukcji. Zarówno dane wyjściowe, jak i wejściowe są przechowywane w osobnych plikach. Ta struktura bada również monitorowanie i planowanie zadań, które nie powiodły się podczas wykonywania, i ponownie je wykonuje. MapReduce został powszechnie przyjęty ze względu na swoją prostotę, skalowalność, szybkość, odzyskiwanie i minimalny przepływ danych. Ma różne ograniczenia: tworzenie wąskich gardeł z powodu ciągłego odczytu dysku, nieefektywność procesów iteracyjnych oraz fakt, że nie jest przeznaczony przede wszystkim do procesów iteracyjnych. ²⁶
YARN	Platforma do planowania zadań i zarządzania zasobami klastra. Początkowo została określona przez Apache jako przeformatowany menedżer zasobów.	W przypadku aplikacji do obsługi Big Data YARN jest obecnie klasyfikowany jako rozproszony system operacyjny na dużą skalę. Podstawową funkcją YARN jest podzielenie funkcjonalności zarządzania zasobami oraz planowania i monitorowania zadań na odrębne demony (procesy drugoplanowe) ²⁷ . Strukturę obliczeniową danych tworzą menedżer węzłów (ang. node manager) i menedżer zasobów (ang. resource manager). Podstawowym procesem decydującym o alokowaniu zasobów pomiędzy wszystkimi aplikacjami w systemie jest menedżer zasobów. Główną funkcją menedżera węzłów jest monitorowanie wykorzystania zasobów,

²⁶ Dean J., Ghemawat S., op.cit., s.107–110

²⁷ Apache Software Foundation, Apache Hadoop YARN, 2021, <https://hadoop.apache.org/docs/current/hadoop-yarn/hadoop-yarn-site/YARN.html> [Dostęp: lipiec 2021]

		takich jak sieć, pamięć, procesor, dysk itp. Posiada funkcje, takie jak obsługa wielu podmiotów, kompatybilność, skalowalność i wykorzystanie klastra ²⁸ .
Apache Pig	Platforma do analizy obszernych zbiorów danych, które mają reprezentację w języku programowania wysokiego poziomu – języku, który jest łatwiejszy do nauki niż niskopoziomowy z powodu bardziej zrozumiałej składni i wyższego poziomu abstrakcji.	Główną cechą Apache Pig jest elastyczna struktura pozwalająca na znaczną wielkość obliczeń równoległych, co umożliwia obsługę dużych zbiorów danych. Obecnie warstwa infrastrukturalna Pig składa się z kompilatora i dwóch faz – mapowania i redukcji. Warstwa językowa Pig składa się z języka tekstowego o nazwie Pig Latin, który zapewnia łatwość programowania, możliwości optymalizacji i rozszerzania. ²⁹
Apache Hive	Oprogramowanie do zarządzania obszernymi zestawami danych i wykonywania zapytań w środowisku rozproszonej pamięci masowej.	Oferuje takie funkcje, jak zapytania tymczasowe, analizę ogromnych zbiorów danych i podsumowania hurtowni danych w Hadoop. Ma infrastrukturę hurtowni danych, która opiera się na Hadoop i zapytaniach w języku podobnym do SQL o nazwie HiveQL. W przypadku trudności z wyrażaniem logiki w programie HiveQL uruchamia również MapReduce developer w celu mapowania i redukcji. Zapewnia szybką reakcję na obszerne zestawy danych, jest skalowalny i umożliwia rozszerzanie. Pozyskiwanie, przetwarzanie i ładowanie danych (ETL) są łatwe, a zapytania są wykonywane przy użyciu MapReduce. ³⁰

²⁸ Vavilapalli V. et al., Apache Hadoop YARN: yet another resource negotiator, Proceedings of the 4th annual Symposium on Cloud Computing, Association for Computing Machinery, artykuł nr 5, 2013, s.2–5

²⁹ Apache Software Foundation, Welcome to Apache Pig!, 2021, <https://pig.apache.org/> [Dostęp: lipiec 2021]

³⁰ Apache Software Foundation, Apache Hive TM, 2021, <https://hive.apache.org/> [Dostęp: lipiec 2021]

Apache Storm	Rozproszony system obliczeń w czasie rzeczywistym do przetwarzania Big Data.	Jest prosty, może być wykorzystany w każdym środowisku programistycznym, jest korzystny dla YARN w zakresie uczenia maszynowego, ETL, ciągłego monitorowania operacji, rozproszonego zdalnego wywoływania procedur (RPC) i analizy w czasie rzeczywistym. Skalowalność, odporność na błędy, niezawodność, szybkość i łatwość obsługi sprawiają, że Storm jest idealny do przetwarzania danych w czasie rzeczywistym. ³¹
Apache Spark	Narzędzie do przetwarzania dużych zbiorów danych.	Został wprowadzony w celu rozwiązania problemów wejścia i wyjścia (I/O) dysku i wydajności Hadoop. Wykonuje obliczenia w pamięci i zapewnia funkcję buforowania danych w pamięci. Spark obsługuje kilka języków programowania (Python, Java i Scala) do przetwarzania dużych wolumenów danych. Przetwarza dane 100 razy szybciej niż Hadoop i MapReduce i posiada mechanizm wykonawczy, który zarządza acyklicznym przepływem danych i przetwarzaniem w pamięci, przez co zajmuje więcej pamięci niż inne platformy Big Data. ³²
Blink DB	Narzędzie do przetwarzania danych o dużej skali za pomocą interaktywnych zapytań SQL.	Umożliwia dostosowanie dokładności zapytania w celu uzyskania szybkiego czasu odpowiedzi i wspólne zapytania dotyczące dużych danych poprzez wykonywanie zapytań na przykładowych danych ³³ . Istnieją dwie główne cechy Blink DB: ma adaptacyjną strukturę optymalizacji, która konstruuje i przechowuje wielowymiarowe próbki z oryginalnych danych w czasie, a także ma strategię odpowiedniego doboru próby, która jest dynamiczna, na podstawie czasu odpowiedzi zapytania i potrzeb dokładności. Głównym celem Blink

³¹ Apache Software Foundation, Apache Storm, 2021, <https://storm.apache.org/> [Dostęp: lipiec 2021]

³² Apache Software Foundation, Apache Spark, 2021, <https://spark.apache.org/> [Dostęp: lipiec 2021]

³³ Carnegie Mellon Database Group, BlinkDB, 2021, <https://dbdb.io/db/blinkdb> [Dostęp: lipiec 2021]

		DB jest obsługa zapytań interaktywnych, tj. agregacji zapytań na dużych ilościach danych ³⁴ .
GNU R	Język programowania służący do analizy statystycznej i jej graficznej reprezentacji.	Oferuje ono szeroki zakres analiz statystycznych: klasyfikację, klasyczne testowanie danych, grupowanie, analizę szeregów czasowych, metody graficzne, modelowanie nieliniowe i liniowe. Skutecznie przetwarza i zapewnia bezpieczne przechowywanie danych, a także gwarantuje płynne działania na macierzach i danych wektorowych, dzięki czemu można zoptymalizować obliczenia statystyczne. Pozwala rozszerzyć bazową funkcjonalność o zewnętrzne pakiety za pomocą sieci archiwów CRAN, dzięki czemu użytkownik może uzyskać dowolne wymagane statystyki. ³⁵

Źródło: opracowanie własne

1.4. Kluczowe zastosowania Big Data

Aplikacje biznesowe i badania naukowe mogą generować ogromne ustrukturyzowane dane, których zarządzanie i analiza opierają się na dojrzałych skomercjalizowanych technologiach, takich jak RDBMS (system zarządzania relacyjną bazą danych), hurtownia danych, OLAP (przetwarzanie danych za pomocą wielowymiarowej bazy danych) i BPM (zarządzanie procesami biznesowymi)³⁶. Analiza danych opiera się głównie na eksploracji danych i analizie statystycznej, choć nadal jest bardzo aktywną dziedziną badawczą, a zapotrzebowanie na nowe zastosowania napędza rozwój nowych metod. Wykorzystywanie charakterystyk danych, eksploracja czasu i przestrzeni może wydobyć struktury wiedzy ukryte w szybkich przepływach danych i czujnikach³⁷. Kierując się ochroną prywatności w handlu

³⁴ Agarwal S. et al., BlinkDB: queries with bounded errors and bounded response times on very large data, Proceedings of the 8th ACM European Conference on Computer Systems, Association for Computing Machinery, 2013, s.33

³⁵ The R Foundation, What is R?, 2021, <https://www.r-project.org/about.html> [Dostęp: lipiec 2021]

³⁶ Agrawal D. et al., Challenges and opportunities with big data, A community white paper developed by leading researchers across the United States, 2012, s.36

³⁷ Gaber M., Zaslavsky A., Krishnaswamy S., Mining data streams: a review, ACM Sigmod Record, vol. 34, nr 2, 2005, s.23

elektronicznym, administracji elektronicznej i aplikacjach opieki zdrowotnej, eksploracja danych w zakresie ochrony prywatności jest rozwijającą się dziedziną badań³⁸.

Dane multimedialne są heterogeniczne i większość takich danych zawiera bogatsze informacje niż dane strukturalne lub dane tekstowe. Wśród zastosowań analizy danych multimedialnych są m.in. podsumowanie, w tym zorientowane tematycznie, danych dźwiękowych oraz wizualnych³⁹, tworzenie opisów na podstawie pojawiających się w danych treści⁴⁰, indeksowanie i wyszukiwanie⁴¹, spersonalizowane rekomendacje na podstawie preferencji⁴².

Analiza danych sieciowych w XXI wieku skupia się głównie na serwisach społecznościowych, które zazwyczaj zawierają ogromne ilości linków, a także danych tekstowych i multimedialnych⁴³. Serwisy te można wizualizować jako dynamiczne wykresy, na których każdy wierzchołek odpowiada użytkownikowi, a krawędzie pokazują stopień powiązania między użytkownikami. Na podstawie takich danych można przewidywać możliwość połączenia dwóch użytkowników w przyszłości⁴⁴. Innym rodzajem analizy połączeń jest badanie zmiany zachowania jednostki pod wpływem innych⁴⁵, które mogą być użyteczne w marketingu, reklamie i rekomendacjach⁴⁶. Analiza treści natomiast jest bardziej skomplikowana, ponieważ ilość danych stale rośnie i treści powinny być automatycznie analizowane w rozsądnym przedziale czasowym. Po drugie, wśród tych danych znajduje się również dużo szumu w postaci spamu⁴⁷.

³⁸ Verykios V. et al., State-of-the-art in privacy preserving data mining, ACM Sigmod Record vol. 33, nr 1, 2004, s.54

³⁹ Ding D. et al., Beyond audio and video retrieval: towards multimedia summarization, Proceedings of the 2nd ACM international conference on multimedia retrieval, 2012, s.2

⁴⁰ Wang M., Ni B., Hua X., Chua T., Assistive tagging: a survey of multimedia tagging with human-computer joint exploration, ACM Computing Surveys, vol. 44, nr 4, 2012, s.25

⁴¹ Hu W. et al., A survey on visual content-based video indexing and retrieval, IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), vol. 41, nr 6, 2011, s.799–802

⁴² Park Y., Chang K., Individual and group behavior-based customer profile model for personalized product recommendation, Expert Systems with Applications, vol. 36, nr 2, 2009, s.1934–1937

⁴³ Aggarwal, C., An introduction to social network data analytics, Social network data analytics, Springer, 2011, s.5

⁴⁴ Scellato S., Noulas A., Mascolo C., Exploiting place features in link prediction on location-based social networks, Proceedings of the 17th ACM SIGKDD international conference on Knowledge discovery and data mining, 2011, s.1047–1051

⁴⁵ Tang J., Sun J., Wang C., Yang Z., Social influence analysis in large-scale networks, Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining, 2009, s.809

⁴⁶ Li Y., Chen W., Wang Y., Zhang Z., Influence diffusion dynamics and influence maximization in social networks with friend and foe relationships, Proceedings of the sixth ACM international conference on Web search and data mining, 2013, s.664

⁴⁷ Dai W. et al., Translated learning: transfer learning across different feature spaces, Proceedings of the 21st International Conference on Neural Information Processing Systems, 2008, s.355–356

Wzrost liczby użytkowników telefonów i lepsza wydajność przyczyniły się do możliwości tworzenia społeczności opartymi na zainteresowaniach i lokalizacji geograficznej. Dzięki mobilności telefonów komórkowych użytkownicy mogą komunikować się z innymi członkami społeczności z dowolnego punktu na Ziemi⁴⁸. Aplikacje społecznościowe wsparły rozwój branży mobilnej, a także pozwoliły zdobyć wykształcenie większej liczbie osób⁴⁹, zmniejszyły nierówności społeczne⁵⁰ oraz pomogły zbudować skuteczniejsze instytucje⁵¹. Wprowadzony został mechanizm analizy surowych danych transportu multimodalnego do monitorowania stanu zdrowia w czasie rzeczywistym⁵².

Analiza danych internetowych jest związana z kilkoma dziedzinami badawczymi, w tym z bazami danych, wyszukiwaniem informacji, przetwarzaniem języka naturalnego (ang. Natural Language Processing, NLP) i eksploracją tekstu (ang. text mining). Analiza jest klasyfikowana na trzy obszary pokrewne: eksploracja treści internetowych (ang. web content mining), eksploracja struktury sieci (ang. web structure mining) oraz eksploracja zachowań w sieci (ang. web usage mining)⁵³. Eksploracja treści internetowych to jest wydobywanie danych tekstowych, wizualnych, dźwiękowych, kodów źródłowych, metadanych oraz hiperłączy. Można ją przeprowadzić metodą wyszukiwania informacji i metodą bazy danych. Metoda wyszukiwania informacji polega na filtrowaniu wyników zgodnie z kryteriami wyszukiwania lub dokumentami konfiguracyjnymi. Metoda bazodanowa natomiast symuluje strukturę danych w sieci, aby umożliwić zapytania oparte na nie tylko na słowach kluczowych. Ponieważ większość danych dotyczących treści internetowych to nieustrukturyzowane dane tekstowe, analiza danych internetowych skupia się głównie na tekście i hipertekście. Eksploracja hipertekstu obejmuje częściowo ustrukturyzowane pliki HTML zawierające hiperłącza.⁵⁴

Eksploracja struktury sieci obejmuje modele budowane w oparciu o struktury topologiczne wyposażone w hiperłącza z opisem lub bez niego. Takie modele wykrywają podobieństwa i korelacje między różnymi stronami internetowymi i służą do ich

⁴⁸ Chen M., Mao S., Liu Y., op.cit., s.197

⁴⁹ Bahia K., Joiner J., Satari A., 2020 Mobile Industry Impact Report: Sustainable Development Goals, GSM Association, 2020, s.63

⁵⁰ Ibidem, s.83

⁵¹ Ibidem, s.103

⁵² Garg M., Kim D., Turaga D., Prabhakaran B., Multimodal analysis of body sensor network data streams for real-time healthcare, Proceedings of the International Conference on Multimedia information retrieval, 2010, s. 472

⁵³ Pal S., Talwar V., Mitra P., Web mining in soft computing framework: Relevance, state of the art and future directions, IEEE Transactions on neural networks, vol. 13, nr 5, 2002, s.1165–1167

⁵⁴ Chakrabarti S., Data mining for hypertext: A tutorial survey, ACM SIGKDD Explorations Newsletter, vol. 1, nr 2, 2000, s.4

klasyfikowania. Page Rank (wyszukiwarka Google)⁵⁵ i CLEVER (projekt IBM)⁵⁶ w pełni wykorzystują modele do wyszukiwania odpowiednich stron internetowych. Zorientowany tematycznie robot (ang. topic-oriented web crawler) to kolejny udany przypadek wykorzystania modeli⁵⁷.

Eksploracja zachowań w sieci ma na celu wydobywanie rejestrów zdarzeń (ang. logs) na serwerach internetowych i serwerach pośredniczących (ang. proxy servers), historii przeglądania z przeglądarek, profili użytkowników, danych rejestracyjnych, sesji sieciowych, zapytań w wyszukiwarkach, kliknięć i przewijań myszy, a także innych danych generowanych przez interakcje z siecią. Eksploracja zachowań w sieci odgrywa kluczową rolę w spersonalizowanej reklamie, e-biznesie, prywatności oraz bezpieczeństwie sieci.⁵⁸

Najpopularniejszym formatem przechowywania informacji w internecie jest tekst, dlatego uważa się, że analiza tekstu ma większy potencjał biznesowy niż ustrukturyzowane dane. Ogólnie rzecz biorąc, analiza tekstu to proces wydobywania przydatnych informacji i wiedzy z tekstu nieustrukturyzowanego. Eksploracja tekstu jest interdyscyplinarna i obejmuje wyszukiwanie informacji, uczenie maszynowe, statystykę, lingwistykę komputerową i eksplorację danych. Większość systemów eksploracji tekstu opiera się na wyrażeniach tekstowych i przetwarzaniu języka naturalnego, z większym naciskiem na NLP. Pozwala ono na analizowanie, interpretowanie, a nawet generowanie tekstu. Popularne metody NLP obejmują przyswajanie języka, pozbywanie się wieloznaczności słów, określenie części mowy i probabilistyczną gramatykę bezkontekstową. Techniki oparte na NLP są stosowane do eksploracji tekstu, w tym pozyskiwania informacji, modeli tematycznych, podsumowania tekstu, klasyfikacji, klasteryzacji, odpowiadania na pytania i analizy sentymentu.⁵⁹

1.5. Rozwój przetwarzania języka naturalnego

Przetwarzanie języka naturalnego (NLP) powstało w latach 50. XX w. jako interdyscyplinarna dziedzina łącząca sztuczną inteligencję z lingwistyką. Dziedzina ta pierwotnie różniła się od wyszukiwania informacji tekstowych (ang. information retrieval, IR),

⁵⁵ Brin S., Page L., The anatomy of a large-scale hypertextual web search engine, Computer networks and ISDN systems, vol. 30, nr 1–7, 1998, s.109–110

⁵⁶ Kumar R., Raghavan P., Rajagopalan S., Tomkins A., Core algorithms in the CLEVER system, ACM Transactions on Internet Technology, vol. 6, nr 2, 2006, s.132–150

⁵⁷ Chakrabarti S., Van den Berg M., Dom B., Focused crawling: a new approach to topic-specific Web resource discovery, Computer networks, vol. 31, nr 11–16, 1999, s.1625–1637

⁵⁸ Chen M., Mao S., Liu Y., op.cit., s.195

⁵⁹ Manning C., Schütze H., Foundations of statistical natural language processing, MIT press, 1999, s.44

które wykorzystywało techniki oparte na statystykach do efektywnego indeksowania i przeszukiwania dużych ilości tekstu⁶⁰. Później jednak NLP i IR stały się bardziej podobne do siebie. Obecnie przetwarzanie języka naturalnego zawiera w sobie kilka bardzo różnorodnych dziedzin, co wymaga od dzisiejszych badaczy i programistów tej dziedziny znacznego poszerzenia swojej bazy wiedzy⁶¹.

Wczesne uproszczone podejścia, na przykład tłumaczenie maszynowe słowo po słowie z rosyjskiego na angielski, zostały pokonane przez homografy (pisane identycznie słowa z wieloma znaczeniami) i metaforę, co doprowadziło do tłumaczenia fragmentu z Biblii „*duch wprowadzie ochoczy, ale ciało słabe*” jako „*wódka jest przyjemna, ale mięso jest zepsute*”.⁶²

W 1956 Chomsky przeprowadził teoretyczną analizę gramatyk językowych⁶³, która pozwoliła oszacować trudność problemu, wpływając na stworzenie notacji Backus-Naur Form (BNF)⁶⁴. Jest ona używana do określenia gramatyki bezkontekstowej (ang. context-free grammar, CFG) i do reprezentowania składni języków programowania⁶⁵. Specyfikacja BNF języka programowania to zestaw reguł derywacji, które wspólnie weryfikują składnię kodu programu.

W latach 70. XX w. generatory analizatorów leksykalnych (ang. lexer) i generatory analizatorów składni (ang. parser), takie jak kombinacja lex/yacc, wykorzystywały gramatyki. Analizator składni przekształca tekst w tokeny; analizator składni weryfikuje kolejność tokenów. Takie generatory znacznie uprościły implementację języka programowania, przyjmując jako dane wejściowe odpowiednio wyrażenia regularne i specyfikacje BNF oraz generując kod i tabele słownikowe (ang. lookup tables), które determinują decyzje dotyczące obu etapów.⁶⁶

Język Prolog⁶⁷ został pierwotnie stworzony w 1970 roku do zastosowania w przetwarzaniu języka naturalnego. Jego składnia jest szczególnie dostosowana do gramatyk,

⁶⁰ Manning C., Raghavan P., Schuetz H., Introduction to Information Retrieval, Cambridge University Press, 2008, s.15-16

⁶¹ Nadkarni P., Ohno-Machado L., Chapman W., Natural language processing: an introduction, Journal of the American Medical Informatics Association, vol. 18, nr 5, 2011, s.546

⁶² Hutchins W., The First Public Demonstration of Machine Translation: the Georgetown-IBM System, 7th January 1954, 2005, s.4, <https://web.archive.org/web/20210103023932/www.hutchinsweb.me.uk/GU-IBM-2005.pdf> [Dostęp: lipiec 2021]

⁶³ Chomsky N., Three models for the description of language, IRE Transactions on information theory, vol. 2, nr 3, 1956, s.115–116

⁶⁴ Aho A., Sethi R., Ullman J., Compilers: principles, techniques, and tools, Addison-Wesley, 1986, s.40-43

⁶⁵ Chomsky N., On certain formal properties of grammars, Information and control, vol. 2, nr 2, 1959, s.140

⁶⁶ Levine J. et al., Lex & yacc, O'Reilly Media Inc., 1992, s.24

⁶⁷ Clocksin W., Mellish C., Programming in Prolog: Using the ISO Standard, Springer, 2003, s.55

choć w najprostszym trybie implementacji (odgórne analizowanie składni) reguły muszą być sformułowane inaczej (rekurencja prawostronna) niż te przeznaczone dla analizatora składni w stylu yacc. Analizatory odgórne są łatwiejsze do zaimplementowania niż oddolne, ale są znacznie wolniejsze.

Lata 80. XX w. rozpoczęły fundamentalną zmianę kierunku podsumowaną przez Kleina. Proste przybliżenia zastąpiły głęboką analizę, oszacowania stały się dokładniejsze, metody uczenia maszynowego stały się kluczowe. Do trenowania algorytmów uczenia maszynowego wykorzystano duże, fragmenty tekstu (korpusy) opatrzone adnotacjami zawierającymi prawidłowe odpowiedzi i zapewniono złote standardy ewaluacji⁶⁸. Ta zmiana kierunku przyczyniła się do powstania statystycznego NLP w latach 90. XX w. Ogólne reguły zastępują liczne szczegółowe reguły, a informacje statystyczne dotyczące częstości względnej mają na celu ujednoznacznienie. Inne podejścia budują probabilistyczne reguły na podstawie danych z adnotacjami, podobnie jak algorytmy uczenia maszynowego, takie jak C4.5⁶⁹, które budują drzewa decyzyjne z wektorów cech. W każdym razie analizator statystyczny określa najbardziej prawdopodobną analizę zdania. Podejścia statystyczne dają dobre wyniki dlatego, że ucząc się na obfitych danych rzeczywistych, wykorzystują najczęściej spotykane przypadki – im bardziej obfite i reprezentatywne są dane, tym wyniki są lepsze i odwrotnie.⁷⁰

Począwszy od 2000 roku zaczęto wykorzystywać sieci neuronowe do prognozowania następnego słowa na podstawie wcześniejszych słów w tekście, co rozpoczęło erę uczenia głębokiego (ang. deep learning) w NLP. W 2003 roku zaproponowano pierwszy model języka „neuronowego”, który składa się z jednowarstwowej sieci neuronowej ze sprzężeniem w przód⁷¹. W 2008 roku do sieci neuronowych zastosowano uczenie wielozadaniowe (ang. multi-task learning), gdzie wiele zadań uczenia się jest rozwiązywanych jednocześnie. Ponieważ modele są coraz częściej oceniane w celu oceny ich zdolności uogólniania, uczenie wielozadaniowe zyskało na znaczeniu i jest obecnie stosowane w szerokim zakresie zadań przetwarzania języka naturalnego⁷².

⁶⁸ Klein D., CS 294-5: Statistical Natural Language Processing, 2005, s.4-5

⁶⁹ Quinlan J., C4.5: Programs for Machine Learning, Morgan Kaufmann Publishers, s.28

⁷⁰ Manning C., Schütze H., op.cit., s.51

⁷¹ Bengio Y., Ducharme R., Vincent P., Janvin C., A neural probabilistic language model, The journal of machine learning research, nr 3, 2003, s.1140–1145

⁷² Collobert R., Weston J., A unified architecture for natural language processing: Deep neural networks with multitask learning, Proceedings of the 25th international conference on Machine learning, 2008, s.162–165

W 2013 roku powstał model osadzania słów Word2Vec, który usprawnił procedurę uczenia się poprzez usunięcie ukrytej warstwy i aproksymację funkcji celu, co umożliwiło uczenie się osadzania słów na dużą skalę w ogromnych korpusach tekstu nieustrukturyzowanego⁷³. W tym samym roku w NLP zaczęto również stosować rekurencyjne sieci neuronowe (ang. recurrent neural networks, RNN)⁷⁴, splotowe (ang. convolutional neural networks, CNN)⁷⁵ oraz rekursywne (ang. recursive neural networks)⁷⁶.

W 2014 roku powstało uczenie sekwencyjne (ang. sequence-to-sequence learning), które służy do mapowania jednej sekwencji na drugą za pomocą sieci neuronowej⁷⁷. Tłumaczenie maszynowe okazało się idealnym zastosowaniem dla uczenia sekwencyjnego, dlatego w 2016 roku Google ogłosił, że serwis Google Translate oficjalnie przełącza się na model sekwencyjny⁷⁸. W 2015 roku wprowadzony został mechanizm uwagi (ang. attention), który jest jedną z głównych innowacji w neuronowym tłumaczeniu maszynowym (ang. neural machine translation, NMT)⁷⁹. Później pojawiła się nowa forma tego mechanizmu o nazwie samoobserwacja (ang. self-attention)⁸⁰, będąca rdzeniem modelu Transformer. W skrócie, jest ona wykorzystywana do analizowania otaczających słów w zdaniu lub akapicie, aby uzyskać wyniki kontekstowe. Ostatnią istotną innowacją w świecie NLP są wstępnie wytrenowane modele językowe (ang. pretrained language models, PLM). Po raz pierwszy zaproponowano je w 2015 roku⁸¹, ale dopiero niedawno odkryto, że są one bardziej efektywne w porównaniu do wcześniej używanych modeli. Główną zaletą PLM jest ich zdolność do uczenia się słów z dużych korpusów tekstowych bez adnotacji, co jest szczególnie ważne w przypadku języków o niskich zasobach, gdzie dane oznakowane są niewystarczające⁸².

⁷³ Mikolov T., Chen K., Corrado G., Dean J., Efficient estimation of word representations in vector space, ICLR, 2013, s.3-7

⁷⁴ Elman J., Finding structure in time, Cognitive science, vol. 14, nr 2, 1990, s.179–211

⁷⁵ LeCun Y., Bottou L., Bengio Y., Haffner P., Gradient-based learning applied to document recognition, Proceedings of the IEEE, vol. 86, nr 11, 1998, s.2278–2324

⁷⁶ Socher R. et al., Recursive deep models for semantic compositionality over a sentiment treebank, Proceedings of the 2013 conference on empirical methods in natural language processing, 2013, s.1631–1642

⁷⁷ Sutskever I., Vinyals O., Le Q., Sequence to sequence learning with neural networks, Advances in neural information processing systems, 2014, s.3104–3112

⁷⁸ Turovsky B., Found in translation: More accurate, fluent sentences in Google Translate, The Keyword Google Blog, 2016, <https://blog.google/products/translate/found-translation-more-accurate-fluent-sentences-google-translate/> [Dostęp: lipiec 2021]

⁷⁹ Chorowski J., Attention-based models for speech recognition, Advances in Neural Information Processing Systems, 2015, s.577–585

⁸⁰ Parikh A., Tackstrom O., Das D., Uszkoreit J., A decomposable attention model for natural language inference, EMNLP, 2016

⁸¹ Dai A., Le Q., Semi-supervised sequence learning, Advances in neural information processing systems, nr 28, 2015, s.3079–3087

⁸² Sun Y. et al., SIFRank: a new baseline for unsupervised keyphrase extraction based on pre-trained language model, IEEE Access, nr 8, 2020, s.10896

1.6. Przebieg analizy sentymentu

Obecnie wielu ludzi wyraża opinie i dzieli się swoimi doświadczeniami przez internet. Analiza sentymentu, inaczej analiza wydźwięku emocjonalnego (ang. sentiment analysis, SA), powstała z powodu wymiany ogromnej ilości informacji. Nie jest możliwe wskazanie dokładnej daty, ale w 2000 roku powstało tylko 37 artykułów, a w roku 2005 opublikowano 101 artykułów naukowych na ten temat. Od tego momentu tempo publikacji znacząco wzrosło – w 2010 powstało 1039, a w 2016 – prawie 7 tysięcy⁸³. Analiza wydźwięku jest stosowana w przetwarzaniu języka naturalnego⁸⁴ do analizowania opinii, uczuć oraz reakcji ludzi na temat wielu produktów i usług. Pomaga również klasyfikować fragmenty tekstu w wielu wymiarach, na przykład jako pozytywne, negatywne lub neutralne, w celu podjęcia właściwych decyzji przez firmy⁸⁵. SA obejmuje pięć etapów przetwarzania danych, które są opisane poniżej⁸⁶.

Zbieranie danych to pierwszy krok w analizie sentymentu. Dane internetowe nie mogą być analizowane ręcznie, ponieważ są nieuporządkowane, wyrażane na różne sposoby za pomocą różnego słownictwa, slangów, kontekstu itp. Jednym z narzędzi używanym na tym etapie jest Twitter Streaming API⁸⁷, które stosuje się do parafrazowania i gromadzenia danych z tweetów (publikacji na portalu Twitter)⁸⁸.

Kolejnym etapem jest przygotowanie tekstów przed ich analizą. Ten proces pozwala pozbyć się zawartości niezwiązanych z analizą. Celem procesu jest identyfikacja i usuwanie treści nieistotnych dla analizy właściwej⁸⁹. W przypadku analizy konkretnych części mowy może być użyteczna technika oznaczania części mowy (ang. part-of-speech tagging)⁹⁰.

⁸³ Mantyla M., Graziotin D., Kuutila M., The evolution of sentiment analysis—A review of research topics, venues, and top cited papers, *Computer Science Review*, vol. 27, 2018, s.20

⁸⁴ Hussein D., A survey on sentiment analysis challenges, *Journal of King Saud University-Engineering Sciences*, vol. 30, nr 4, 2018, s.333–334

⁸⁵ Aqlan A., Manjula B., Naik R., A Study of Sentiment Analysis: Concepts, Techniques, and Challenges, *Proceedings of International Conference on Computational Intelligence and Data Engineering*, 2019, s.148

⁸⁶ D'Andrea A., Ferri F., Grifoni P., Guzzo T., Approaches, Tools and Applications for Sentiment Analysis Implementation, *International Journal of Computer Applications*, vol. 125, nr 3, 2015, s.26

⁸⁷ Xu W., Ritter A., Grishman R., Gathering and generating paraphrases from twitter with application to normalization, *Proceedings of the sixth workshop on building and using comparable corpora*, 2013, s.121–128

⁸⁸ Hazra T., Ghosh A., Sengupta A., Mukherjee N., Mitigating the adversities of social media through real time tweet extraction system, *2015 International Conference and Workshop on Computing and Communication*, 2015, s.3–5

⁸⁹ El-Din D., Mokhtar H., Ismael O., Online paper review analysis, *International Journal of Advanced Computer Science and Applications*, vol. 6, nr 9, 2015, s.223–226

⁹⁰ Yumusak S., Dogdu E., Kodaz H., Tagging accuracy analysis on part-of-speech taggers, *Journal of Computer and Communications*, vol. 2, nr 4, 2014, s.157–158

Wykrywanie sentymentu to proces poszukiwania emocji w tekście polegający na badaniu fraz i zdań. Zachowywane są wszystkie zdania zawierające uzewnętrznienie, takie jak poglądy, opinie i frazy niecenzuralne, a zdania o charakterze obiektywnym nie są brane pod uwagę.⁹¹

Klasyfikacja sentymentu to zadanie polegające na wyodrębnieniu i sklasyfikowaniu fragmentu tekstu. Istnieją trzy główne poziomy klasyfikacji:

- poziom dokumentu: klasyfikuje dokument jako wyrażający pozytywną, negatywną albo neutralną opinię lub sentyment. Cały dokument przedstawiający jeden temat traktuje się jako podstawową jednostkę informacyjną;
- poziom zdania: klasyfikuje sentymenty wyrażone w każdym zdaniu;
- poziom aspektu: klasyfikuje wydźwięk w odniesieniu do konkretnych aspektów produktu lub usługi. Użytkownicy mogą wyrażać różne opinie na temat różnych aspektów tego samego podmiotu.⁹²

Ten etap obejmuje wiele technik, które można podzielić na trzy główne podejścia, a mianowicie metody statystyczne, czyli uczenie maszynowe, podejście leksykalne (ang. *lexicon-based approach*)⁹³, a także podejście hybrydowe⁹⁴. Kategoryzacja technik przedstawiona jest na Rysunku 1.


⁹¹ D'Andrea A., Ferri F., Grifoni P., Guzzo T., op.cit., s.27

⁹² Ibidem

⁹³ Vaghela V., Jadav B., Analysis of Various Sentiment Classification Techniques, *International Journal of Computer Applications*, vol. 140, nr 3, 2016, s.24

⁹⁴ Biltawi M. et al., Sentiment classification techniques for Arabic language: A survey, 7th International Conference on Information and Communication Systems, 2016, s.339

Rysunek 1. Techniki klasyfikacji sentymentów



Źródło: opracowanie własne na podstawie Medhat W., Hassan A., Korashy H., Sentiment analysis algorithms and applications: A survey, Ain Shams engineering journal, vol. 5, nr 4, 2014, s.1095

Technika naiwnych klasyfikatorów bayesowskich (ang. naive Bayes classifiers, NBC) i maszyn wektorów nośnych (ang. support-vector machines, SVM) są bardziej popularne i wykorzystywane do klasyfikacji sentymentu. Techniki te mogą poprawić dokładność klasyfikacji, ponieważ są proste i szybkie⁹⁵.

1.6.1. Podejście leksykalne

Wiele słów jest używanych do klasyfikacji sentymentu – pozytywnych słów dla pożądanых rzeczy, a negatywnych słów dla rzeczy niepożądanych. Tak więc, podejście

⁹⁵ Goel A., Gautam J., Kumar S., Real time sentiment analysis of tweets using Naive Bayes, 2nd International Conference on Next Generation Computing Technologies, 2016, s.259

leksykalne polega głównie na znalezieniu słów wyrażających opinie i używanie ich do analizy tekstu. Istnieją dwie metody oparte na tym podejściu. Pierwsza z nich to metoda korpusowa, a druga to metoda słownikowa.

Metoda korpusowa zaczyna się od początkowej listy słów opiniotwórczych, a następnie znajduje inne słowa na podstawie dużego korpusu, aby uzyskać opinie z określonych kierunków. Procedura SentenceOrientation jest jedną z najważniejszych do reprezentowania tej metody⁹⁶. Pierwszym krokiem w procedurze jest stworzenie listy początkowej i użycie jej z szerokim zakresem ograniczeń językowych, aby móc zidentyfikować dodatkowe słowa, w tym ich wydźwięk. Metoda korpusowa jest stosowana przy użyciu jednej z dwóch metod podrzędnych – statystycznej i semantycznej:

- Metoda statystyczna polega na identyfikowaniu wydźwięku słów na podstawie częstotliwości występowania w korpusie z adnotacjami. Jeśli słowo występuje częściej wśród tekstów negatywnych, to ma negatywny wydźwięk, jeśli wśród pozytywnych, to pozytywny, a w przypadku podobnej częstotliwości oznaczone jest jako neutralne. Jeżeli dwa słowa często pojawiają się razem w tym samym kontekście, to prawdopodobnie mają taki sam wydźwięk. Najbardziej znane zastosowanie polega na wykrywaniu fałszywych opinii poprzez przeprowadzenie testu serii (ang. runs test) do weryfikacji losowości próby.⁹⁷
- Metoda semantyczna nadaje wartości sentymentalne, opierając się na różnych zasadach obliczania podobieństwa między słowami. Słowom bliskim semantycznie nadaje się podobne wartości. Pomocą przy takim podejściu służą słowniki typu WordNet, które są relacyjnymi słownikami semantycznymi, gdzie każde słowo jest połączone wzajemnymi relacjami. Pozwalają one na określenie wydźwięku słowa poprzez znalezienie synonimów i antonimów, a następnie nacechowanie słowa emocjonalnie na podstawie większej liczby połączonych z nim słów o konkretnym wydźwięku.⁹⁸

⁹⁶ Hu M., Liu B., Mining and summarizing customer reviews, Proceedings of the tenth ACM SIGKDD international conference on Knowledge discovery and data mining, 2004, s.168–177

⁹⁷ Kim S., Hovy E., Determining the sentiment of opinions, Proceedings of the 20th International Conference on Computational Linguistics, 2004, s.1367–1373

⁹⁸ Mohammad S., Dunne C., Dorr B., Generating high-coverage semantic orientation lexicons from overtly marked words and a thesaurus, Proceedings of the 2009 conference on empirical methods in natural language processing, 2009, s.601–603

Metoda słownikowa opiera się na ręcznie dobranej niewielkiej grupie słów⁹⁹, którą uzupełniano za pomocą synonimów i antonimów ze słowników. Proces się powtarza do momentu, gdy nowe słowa nie zostaną znalezione¹⁰⁰.

1.6.2. Uczenie maszynowe

Uczenie maszynowe w kontekście analizy wydźwięku służy do rozwiązywania problemów związanych z klasyfikacją tekstów zawierających cechy składniowe lub językowe. Algorytmy uczenia maszynowego są podzielone na uczenie przez wzmacnianie, uczenie nienadzorowane oraz uczenie nadzorowane.

Technika uczenia przez wzmacnianie polega na wchodzenie algorytmu w interakcje ze środowiskiem, a nie z zestawem danych uczących, jak to wygląda w przypadku dwóch pozostałych technik uczenia maszynowego. Algorytm automatycznie pobiera dane ze środowiska i jest uruchomiony, dopóki nie jest osiągnięty postawiony cel.¹⁰¹

Uczenie nienadzorowane jest unikalnym rodzajem algorytmu uczenia maszynowego używanym w większości przypadków do wyciągania różnorodnych wniosków z danych wejściowych niezawierających adnotacji. Technika ta jest stosowana, gdy niemożliwe jest uzyskanie dokumentów z adnotacjami.¹⁰²

Uczenie nadzorowane wykorzystuje zestaw danych uczących do tworzenia prognoz. Ten zestaw danych zawiera dane wejściowe oraz wymagana przez nauczyciela odpowiedź. Do metod uczenia nadzorowanego należą: klasyfikatory probabilistyczne, klasyfikatory regułowe, klasyfikatory liniowe oraz drzewa decyzyjne.¹⁰³

Klasyfikatory probabilistyczne przewidują prawdopodobieństwa przynależności obserwacji do wielu klas, co pozwala stosować dodatkowe reguły w celu elastycznego przypisania klas w zależności od potrzeby. Główne rodzaje klasyfikatorów probabilistycznych to są:¹⁰⁴

⁹⁹ Hatzivassiloglou V., McKeown K., Predicting the semantic orientation of adjectives, 35th annual meeting of the association for computational linguistics and 8th conference of the european chapter of the association for computational linguistics, 1997, s.175

¹⁰⁰ Medhat W., Hassan A., Korashy H., Sentiment analysis algorithms and applications: A survey, Ain Shams engineering journal, vol. 5, nr 4, 2014, s.1096

¹⁰¹ Aqlan A., Manjula B., Naik R., op.cit., s.151

¹⁰² Ibidem

¹⁰³ Ibidem

¹⁰⁴ Hastie T., Tibshirani R., Friedman J., The Elements of Statistical Learning 2nd ed., Springer, 2009, s.348

- Maksymalna entropia uwzględnia informacje z różnorodnych i potencjalnie nakładających się cech, które mogą być warunkowo zależne. Cechy są funkcjami binarnymi łączącymi klasy z różnymi elementami kontekstu zdań. Główną ideą modelu maksymalnej entropii jest to, że model powinien spełniać wszystkie ograniczenia nałożone przez dane uczące, pozostając jak najbardziej bezstronnym. Osiągane jest to poprzez wybór modelu o maksymalnej entropii, czyli najbardziej równomiernym rozkładzie, biorąc pod uwagę ograniczenia.¹⁰⁵
- Podstawowym założeniem sieci bayesowskiej jest występowanie związków przyczynowych między zmiennymi zobrazowanymi na skierowanym grafie acyklicznym i niezależność poszczególnych zmiennych od innych, nie będących w bezpośredniej relacji. Innym (nieobowiązkowym) założeniem jest posiadanie tylko tych zmiennych, które mają parę w danych. Na przykład taka sieć może reprezentować relacje między chorobami a objawami. Znając objawy, można uzyskać prawdopodobieństwa występowania poszczególnych chorób.¹⁰⁶
- Naiwne klasyfikatory bayesowskie są jednymi z najprostszych klasyfikatorów probabilistycznych. W tym modelu zakłada się, że wszystkie cechy są warunkowo niezależne od danej klasy. W procesie uczenia tego klasyfikatora o znanej strukturze, prawdopodobieństwa klas i prawdopodobieństwa warunkowe są obliczane na podstawie danych uczących, a następnie wartości tych prawdopodobieństw są wykorzystywane do klasyfikacji nowych obserwacji.¹⁰⁷

Klasyfikatory regułowe opierają się na regułach jeśli-to (ang. if-then) do przewidywania klas. Schematy takich klasyfikatorów zazwyczaj składają się z algorytmu indukcji reguł (tworzenie reguł na podstawie obserwacji), miar rankingu reguł (sporządzenie listy najlepiej dopasowanych reguł) oraz algorytmu przewidywania klasy (wybranie klasy na podstawie reguł).¹⁰⁸

Klasyfikatory liniowe pozwalają decydować w oparciu na wartości liniowej kombinacji cech. Charakterystyki obiektu są również znane jako wartości cech i są zazwyczaj

¹⁰⁵ Merity S., Murphy T., Curran J., Accurate argumentative zoning with maximum entropy models, Proceedings of the 2009 Workshop on Text and Citation Analysis for Scholarly Digital Libraries, 2009, s.20–21

¹⁰⁶ Cheng J., Druzdel M., AIS-BN: An adaptive importance sampling algorithm for evidential reasoning in large Bayesian networks, Journal of Artificial Intelligence Research, vol. 13, 2000, s.157–158

¹⁰⁷ Yang F., An implementation of naive bayes classifier, 2018 International Conference on Computational Science and Computational Intelligence, 2018, s.301

¹⁰⁸ Tung A., Rule-based Classification, Encyclopedia of Database Systems, Springer Publishing Company, 2009, s.2459

przedstawiane maszynie w wektorze zwanym wektorem cech. Taki typ klasyfikatorów podzielono na dwie metody:

- Sieci neuronowe to są algorytmy oparte na rozpoznawaniu zależności znajdujących się w kilku zestawach danych za pomocą procesu podobnego do działania ludzkiego umysłu.¹⁰⁹
- Maszyny wektorów nośnych służą do analizowania zestawów danych w celu klasyfikacji i analizy regresji. Pozwalają wyznaczyć hiperpłaszczyznę do rozdzielania obiektów na dwie klasy.¹¹⁰

Drzewa decyzyjne mają na celu podzielenie dużych danych na małe grupy, aby ułatwić nadzorowanie. W tym celu używane są wielowartościowe cechy obiektów, co pozwala przewidzieć klasę dla nowych obiektów.¹¹¹

1.6.3. Podejście hybrydowe

Podejście hybrydowe łączy w sobie wiele technik i metod z podejścia leksykalnego i uczenia maszynowego, które dają bardziej efektywne wyniki niż te same techniki osobno. Pozwala to na łączenie zarówno uczenia nadzorowanego, jak i nienadzorowanego, a także częściowo nadzorowanego (połączenie małego zestawu danych etykietowanych z dużym zbiorem danych nieoznakowanych). Główne zalety tego podejścia to wykrywanie i pomiar wydźwięku na poziomie koncepcji oraz mniejsza wrażliwość na zmiany w zakresie tematu.¹¹²

¹⁰⁹ Aqlan A., Manjula B., Naik R., op.cit., s.152

¹¹⁰ Ibidem

¹¹¹ Ibidem

¹¹² D'Andrea A., Ferri F., Grifoni P., Guzzo T., op.cit., s.30

Rozdział II. Przygotowanie do analizy regresji

Na potrzeby analizy sentymentu została wybrana metoda słownikowa z podejścia leksykalnego, ponieważ dla języka polskiego istnieje niewiele korpusów, a co więcej w metodzie korpusowej ważny jest kontekst, a także rodzaj tekstów. W związku z tym, że w danej pracy badane są opisy aukcji na platformie Allegro, żaden ze znalezionych korpusów nie nadaje się do takiej analizy.

2.1. Budowanie słownika

Podstawowy słownik zawierał 2902 słowa (1676 rzeczowników, 614 czasowników, 612 przymiotników) w kolejności alfabetycznej¹¹³. Został stworzony przez naukowców z Instytutu biologii doświadczalnej PAN im. Marcelego Nenckiego i nazwany jako NAWL (ang. Nencki Affective Word List, czyli lista słów z emocjami)¹¹⁴. Dany słownik jest polską adaptacją wersji niemieckiej BAWL-R (ang. Berlin Affective Word List–Reloaded)¹¹⁵, powszechnie używanej do badania afektywnych właściwości niemieckich słów.

Dane zostały zebrane za pomocą ankiety, w której brało udział 265 polskich uczestników (132 kobiet i 133 mężczyzn w wieku 18-60), dla których język polski jest językiem ojczystym. Każdy z uczestników ocenił 291 słów pod względem 5 podstawowych emocji (radość, gniew, smutek, lęk i wstręt) w skali 1–7, gdzie 1 to najniższe natężenie, a 7 – najwyższe. Ogólna liczba ocen wyniosła 385 575, na podstawie których później zostały policzone średnie dla każdej emocji dotyczącej poszczególnych słów.¹¹⁶

Opis zmiennych:

- Word – słowo w kolejności alfabetycznej
- Category – kategoria, która została przypisana słowu, w tym U (uncategorized, nieskategoryzowana) oraz N (neutral, neutralna)
- mean Happiness – średnia ocen radości dla danego słowa
- mean Anger – średnia ocen gniewu dla danego słowa
- mean Sadness – średnia ocen smutku dla danego słowa

¹¹³ <https://exp.lobi.nencki.gov.pl/nawl-analysis>

¹¹⁴ Riegel M. et al., Nencki Affective Word List (NAWL): the cultural adaptation of the Berlin Affective Word List–Reloaded (BAWL-R) for Polish, *Behavior Research Methods*, vol. 47, nr 4, 2015, s.1222–1236

¹¹⁵ Võ M. et al., The Berlin Affective Word List Reloaded (BAWL-R), *Behavior Research Methods*, vol. 41, nr 2, 2009, s.534–538

¹¹⁶ Wierzbą M. et al., Basic Emotions in the Nencki Affective Word List (NAWL BE): New Method of Classifying Emotional Stimuli, *PLOS ONE*, vol. 10, nr 7, 2015, e0132305, s.3-5

- mean Fear – średnia ocen lęku dla danego słowa
- mean Disgust – średnia ocen wstrętu dla danego słowa
- distance to H – odległość słowa od centroidy skupienia radości
- distance to A – odległość słowa od centroidy skupienia gniewu
- distance to S – odległość słowa od centroidy skupienia smutku
- distance to F – odległość słowa od centroidy skupienia lęku
- distance to D – odległość słowa od centroidy skupienia wstrętu
- distance to N – odległość słowa od centroidy skupienia neutralności.

Rysunek 2. Przykładowa część danych słownika NAWL

word	category	mean Happiness	mean Anger	mean Sadness	mean Fear	mean Disgust	distance to H	distance to A	distance to S	distance to F	distance to D	distance to N
abdykować	U	1.6923077	1.5769231	2.2307692	1.9615384	1.3846154	5.9574866	6.1621423	5.4800406	5.8503165	6.3608594	2.4855323
absurd	A	2.1538463	3.4230769	2.1923077	2.3461537	2.4230769	6.6143265	5.495569	6.905635	6.7415257	6.5050125	4.5181966
adiutant	N	1.962963	1.4814814	1.5185186	1.6666666	1.3333334	5.5321236	6.0936794	6.051804	5.8726435	6.214579	1.7379705
administracja	U	1.7307693	3.3846154	2.1923077	2.5769231	2.6538463	7.1842833	5.7856984	6.970444	6.664787	6.563543	4.344772
adoptować	U	3.5925925	1.925926	2.2592592	2.8148148	1.4074074	5.208091	7.0943513	6.630127	6.284074	7.4977865	4.239305
adresat	N	2.7307692	1.5769231	1.5	1.7307693	1.3846154	4.8601975	6.3089557	6.387512	6.141689	6.4886584	2.4205694
Adriatyk	U	3.7777777	1.2592592	1.3703704	1.8518518	1.1111112	3.8883152	6.8606153	6.8135233	6.3496213	7.026409	3.256809
adwentowy	U	3.3703704	1.8148148	1.962963	1.4814814	1.6666666	4.4106603	6.5432415	6.415481	6.9416695	6.7277718	3.9605236
adwokat	F	2.3076923	2.2307692	2.2307692	3.3846154	2.0769231	6.3912306	6.7431355	6.7532525	5.487205	6.8111553	4.2239237
afekt	N	1.5384616	2.0384614	1.6153846	1.7692307	1.5	6.0499945	5.531327	6.044503	5.869571	6.135062	2.1027772
agent	F	1.6153846	2.5769231	1.5	2.8076923	2.3461537	6.799603	5.9617925	6.983129	5.481802	6.188018	3.688149
agresywny	U	1.3846154	4.5	3.7307692	4.9615383	3.7692308	9.1789665	6.867979	7.6465383	6.5660334	7.614723	7.06634

Źródło: opracowanie własne

Rysunek 2 pokazuje przykładowe dane ze słownika. Kolejnym krokiem było usunięcie z listy słów nazw własnych (np. Adriatyk, jak widać na Rysunku 2). Z tabeli została również usunięta kolumna category, która zawiera pierwszą literę kategorii, do której zostało przypisane dane słowo, ponieważ nie została wykorzystana do analizy regresji oraz z powodu braku przypisania 2163 słów z 2902 do jakiegokolwiek kategorii (litera U w kolumnie category).

Aby rozszerzyć słownik docelowy, został pobrany słownik o nazwie Morfologik zawierający prawie 3,5 mln form słów¹¹⁷, który jest wynikiem projektu PoliMorf¹¹⁸. Tabela 2 poniżej obrazuje formy słowa „człowiek”. Zestaw danych zawiera trzy kolumny: formę podstawową słowa, możliwą formę słowa oraz cechy morfologiczne, które ostatecznie nie zostały włączone do słownika z powodu braku wartości dodanej takich danych w analizie regresji. Następnie do każdego słowa w formie podstawowej w słowniku docelowym zostały dodane formy ze słownika Morfologik.

¹¹⁷ <https://github.com/morfologik/polimorfologik/releases/download/2.1/polimorfologik-2.1.zip>

¹¹⁸ <http://zil.ipipan.waw.pl/PoliMorf>

Tabela 2. Formy słowa „człowiek” w słowniku Morfologik

Podstawowa	Forma	Cechy morfologiczne
człowiek	człowiecze	subst:sg:voc:m1
człowiek	człowiek	subst:sg:nom:m1
człowiek	człowieka	subst:sg:acc:m1+subst:sg:gen:m1
człowiek	człowiekiem	subst:sg:inst:m1
człowiek	człowiekowi	subst:sg:dat:m1
człowiek	człowieku	subst:sg:loc:m1+subst:sg:voc:m1

Źródło: opracowanie własne

Słownik morfologiczny Morfologik zawierał również skróty, w tym jednoliterowe. Niejednoznaczne skróty oraz formy zaczynające się od „nie-” dla form podstawowych słów niezawierających przedrostka „nie-” zostały usunięte ze słownika, ponieważ wydźwięk emocjonalny tych form może znacznie odbiegać od form podstawowych. Po rozszerzeniu słownika o inne formy liczba słów wzrosła z 2902 do 68 963. Ostateczna wersja słownika przedstawiona została w Tabeli 3. Nazwy zmiennych wyrażających odległość słowa od centroidy skupienia poszczególnych emocji zostały skrócone, a średnie ocen emocji dla danego słowa w nazwie zmiennych nie zawierają „mean”.

Tabela 3. Formy słowa „akcja” w finalnej wersji słownika

Word	Happiness	Anger	Sadness	Fear	Disgust	Happiness_dist	Anger_dist	Sadness_dist	Fear_dist	Disgust_dist	Neutral_dist
akcja	3.846	1.692	1.500	2.615	1.346	4.280	6.817	7.000	5.846	7.134	3.920
akcjach	3.846	1.692	1.500	2.615	1.346	4.280	6.817	7.000	5.846	7.134	3.920
akcjami	3.846	1.692	1.500	2.615	1.346	4.280	6.817	7.000	5.846	7.134	3.920
akcją	3.846	1.692	1.500	2.615	1.346	4.280	6.817	7.000	5.846	7.134	3.920
akcje	3.846	1.692	1.500	2.615	1.346	4.280	6.817	7.000	5.846	7.134	3.920
akcję	3.846	1.692	1.500	2.615	1.346	4.280	6.817	7.000	5.846	7.134	3.920
akcji	3.846	1.692	1.500	2.615	1.346	4.280	6.817	7.000	5.846	7.134	3.920
akcjo	3.846	1.692	1.500	2.615	1.346	4.280	6.817	7.000	5.846	7.134	3.920
akcjom	3.846	1.692	1.500	2.615	1.346	4.280	6.817	7.000	5.846	7.134	3.920

Źródło: opracowanie własne

2.2. Wydobywanie danych z Allegro.pl

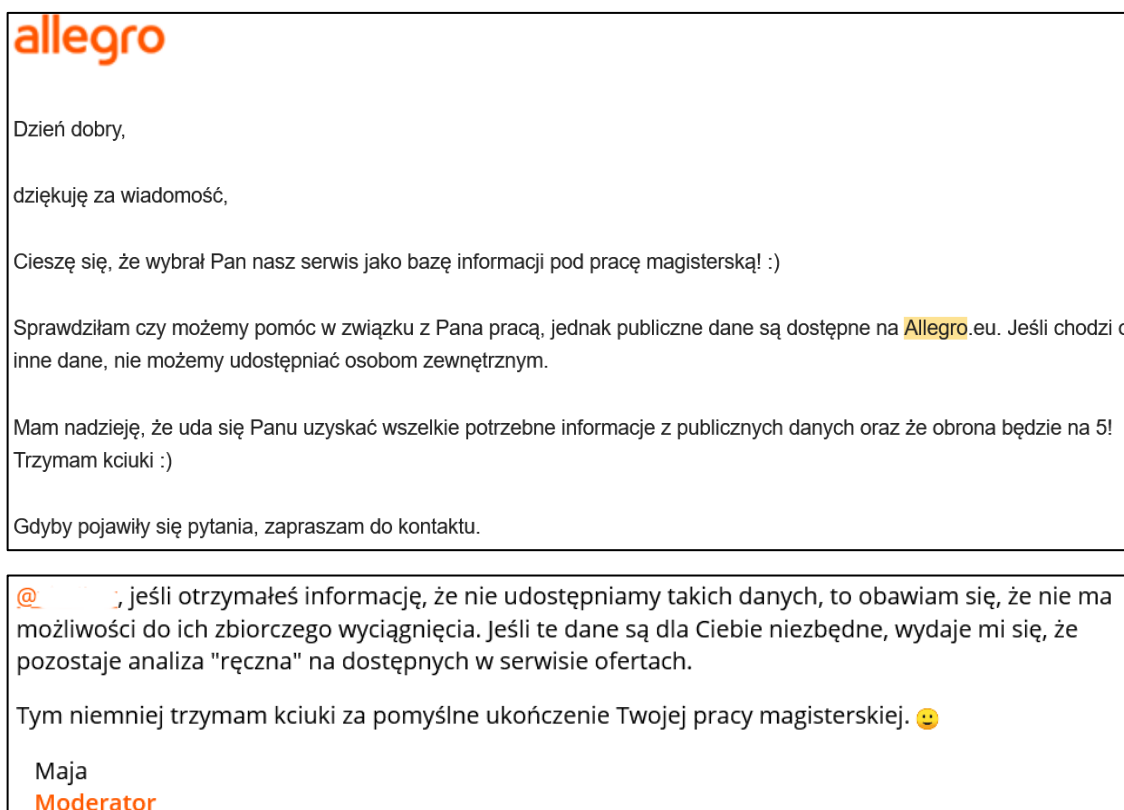
Kolejnym elementem potrzebnym do regresji są dane. W tym celu zostały wydobyte dane z Allegro – jednej z największych platform handlowych na rynku polskim. Według portalu Similarweb, który bada różne aspekty stron internetowych, Allegro znajduje się na 108. pozycji w rankingu ogólnosiwiatowym, na 5. pozycji w Polsce oraz na 1. pozycji w kategorii E

commerce and Shopping > Marketplace pod względem ruchu na stronie¹¹⁹. Została również podjęta próba uzyskania danych z platformy Aliexpress.com, która zajmuje 55. pozycję w rankingu ogólnoświatowym¹²⁰, natomiast z przyczyn niezależnych od autora pracy próba ta nie powiodła się. Przeszkodą był brak potrzebnej zawartości strony przy wydobywaniu treści z platformy, mimo że takie informacje znajdują się na wyświetlanej przez przeglądarkę stronie. Zdaniem autora główną przyczyną nieudanej próby jest sposób generowania treści na platformie Aliexpress, a dokładniej generowanie treści przez skrypty w języku JavaScript.

2.2.1. Przygotowanie do wydobywania danych

Zanim przystąpiono do samodzielnego wydobywania danych z platformy Allegro, zwrócono się do Allegro z prośbą o udostępnienie takich danych. Odpowiedzi zamieszczone są na Rysunkach 3 i 4. Na mail od promotora niniejszej pracy nie uzyskano żadnej odpowiedzi.

Rysunek 3, 4. Odpowiedzi Allegro na prośbę o udostępnienie danych do pracy magisterskiej



Źródła: mail ze skrzynki pocztowej; forum Allegro

Do wydobywania danych z Allegro metodą ekstrakcji danych ze strony (ang. web scraping) został użyty program napisany w języku Python. Podstawową biblioteką do

¹¹⁹ <https://www.similarweb.com/website/allegro.pl/>

¹²⁰ <https://www.similarweb.com/website/aliexpress.com/>

wykonywania zapytań HTTP jest biblioteka o nazwie Requests. Pozwala ona wykonać zapytania i otrzymać źródło strony w formacie HTML. W przypadku Allegro biblioteka ta nie jest skuteczna, ponieważ od kilku miesięcy witryna blokuje zapytania podobne do tych, które mogą być wykonane przez boty internetowe. Najpierw do zapytania zostały dodane nagłówki (ang. request headers), żeby zapytania dla strony wyglądały tak samo jak podczas otwierania w przeglądarce internetowej.

Kolejnym krokiem było używanie biblioteki Requests-html zamiast requests. Jedną z zalet tej biblioteki jest możliwość przetwarzania skryptów w języku JavaScript, które są jednym z podstawowych elementów współczesnych witryn internetowych poza HTML oraz CSS. Jednak ta metoda nie była skuteczna i strona zwracała błąd z kodem 403 (Forbidden), czyli serwer widział zapytanie, natomiast z nieznanych powodów nie chciał zwrócić zawartości strony.

Ostatecznie do wydobywania danych została wybrana biblioteka Selenium posiadająca wymaganą funkcjonalność w postaci WebDrivera, który wykonuje zapytania za pomocą przeglądarki internetowej poprzez API. Poza samą przeglądarką wymagany jest program pełniący funkcje pełnomocnika (ang. proxy), aby umożliwić przepływ danych pomiędzy programem w języku Python, przeglądarką oraz internetem. W zależności od przeglądarki należy pobrać odpowiedni program i zamieścić go w wybranym folderze. Do wydobywania danych została wybrana przeglądarka Mozilla Firefox, a zatem został pobrany program o nazwie Geckodriver. Program ten pozwala sterować przeglądarką w trybie automatycznym za pomocą kodu w języku Python, jednak możliwe jest również sterowanie ręczne, co okazało się bardzo użyteczne, ponieważ pozwala rozwiązać CAPTCHA. Taka konfiguracja umożliwiła bezproblemową ekstrakcję potrzebnych danych ze stron na platformie Allegro.

2.2.2. Wybór kategorii

Najpierw pobrano wszystkie linki kategorii ze strony o tytule Mapa kategorii Elektronika¹²¹. Kategoria Elektronika została wybrana ze względu na kierunek studiów oraz instytut, do którego przynależy promotor niniejszej pracy – Instytut Informatyki i Gospodarki Cyfrowej. Następnie z każdej strony kategorii została wydobyta liczba ofert w danej kategorii. We wszystkich działaniach związanych ze stronami internetowymi analizę wspierała biblioteka BeautifulSoup. Pozwala ona stosunkowo szybko i skutecznie znaleźć potrzebne elementy na

¹²¹ <https://allegro.pl/mapa-strony/elektronika>

stronie. Po przeprowadzonej analizie powstały dwie kolumny – z adresem URL kategorii oraz z aktualną liczbą ofert. W Tabeli 4 jest przedstawiony fragment danych posortowanych malejąco według liczby ofert. Każda z kategorii zamieszczona w tabeli zawiera w sobie podkategorie. Praktycznie w każdej kategorii z tabeli to są urządzenia, a także akcesoria do nich. W związku z tym kategorie te nie były brane pod uwagę przy wyborze kategorii do analizy.

Tabela 4. Kategorie pod względem liczby ofert

URL	Oferty
https://allegro.pl/kategoria/telefony-i-akcesoria	13 366 283
https://allegro.pl/kategoria/akcesoria-gsm-348	12 648 416
https://allegro.pl/kategoria/akcesoria-gsm-etui-i-pokrowce-353	9 407 930
https://allegro.pl/kategoria/komputery	7 836 216
https://allegro.pl/kategoria/rtv-i-agd	4 239 397
https://allegro.pl/kategoria/drukarki-i-skanery-4578	2 983 203
https://allegro.pl/kategoria/czesci-do-laptopow-77801	2 291 169
https://allegro.pl/kategoria/drukarki-i-skanery-tonery-123782	1 708 002

Źródło: opracowanie własne

Jak widać z Tabeli 5, po wyeliminowaniu kategorii z podkategoriami zostały kategorie zawierające same urządzenia, co oznacza, że opisy oraz oceny nie będą się mocno różniły od siebie. Poza tymi elementami ofert do analizy również zostały wydobyte liczby sprzedanych jednostek dla poszczególnych aukcji w celu późniejszego przemnożenia przez ceny, aby otrzymać wartości sprzedaży. Z poniższej listy zostały wybrane kategorie, w których się znajdują urządzenia wielofunkcyjne, czyli Konsole i automaty, Laptopy oraz Smartfony. Po przeanalizowaniu pierwszej kategorii stwierdzono, że produkty z ofert w tej kategorii nie są homogeniczne pod względem funkcyjnym – znajdują się w niej zarówno tetrisy, stacjonarne automaty do gier, konsole starszych generacji, które służą wyłącznie do grania, a także konsole nowych generacji, zarówno przenośne, jak i stacjonarne. W związku z tym została wybrana kolejna kategoria pod względem wielkości potencjalnej próby.

Tabela 5. Kategorie po wyeliminowaniu kategorii z podkategoriami

URL	Oferty
https://allegro.pl/kategoria/smartwatche-i-akcesoria-smartwatche-257988	170 130
https://allegro.pl/kategoria/sluchawki-bezprzewodowe-85166	115 739
https://allegro.pl/kategoria/konsole-i-automaty	112 779
https://allegro.pl/kategoria/zestawy-sluchawkowe-bezprzewodowe-4863	111 172
https://allegro.pl/kategoria/laptopy-491	105 100
https://allegro.pl/kategoria/zestawy-sluchawkowe-przewodowe-4862	83 468
https://allegro.pl/kategoria/sluchawki-przewodowe-257109	77 137
https://allegro.pl/kategoria/smartfony-i-telefony-komorkowe-165	76 330

Źródło: opracowanie własne

Na Rysunku 5 znajduje się fragment kodu, za pomocą którego powstała analiza kategorii. Pierwszy akapit wydobywa linki do stron kategorii, a następnie tworzy z nich list. Drugi akapit zawiera parametry niezbędne do ekstrakcji liczebności kategorii, a w trzecim znajduje się kod pozwalający wyciągnąć interesujące elementy na podstawie nazwy klasy. W tym przypadku to są liczby ofert w poszczególnych kategoriach.

Rysunek 5. Fragment kodu wspierającego analizę kategorii Allegro

```

driver.get('https://allegro.pl/mapa-strony/elektronika')
html = driver.page_source
soup = BeautifulSoup(html, "lxml")
driver.close()
links = [link['href'] for link in soup.find_all('a', href=True)]
categories = []
for i in range(len(links)):
    if '/kategoria/' in links[i]:
        categories.append("https://allegro.pl" + links[i])

oferty = []
timeout = 30
options = Options()
profile = webdriver.FirefoxProfile()
binary = FirefoxBinary('D:\\Firefox\\App\\Firefox64\\firefox.exe')
exec_path = r'D:/Firefox/geckodriver.exe'
driver = webdriver.Firefox(executable_path=exec_path, firefox_binary=binary, firefox_profile=profile, options=options)

for cat in categories:
    driver.get(cat)
    try:
        WebDriverWait(driver, timeout).until(EC.presence_of_element_located((By.CLASS_NAME, '_11fdd_39FjG')))
    except TimeoutException:
        print("Timed out waiting for page to load")
    offer = driver.find_elements_by_class_name("_11fdd_39FjG")
    for i in range(len(offer)):
        oferty.append([offer[i].text])
driver.close()

```

Źródło: opracowanie własne

2.2.3. Wydobywanie linków do poszczególnych ofert w wybranej kategorii

W celu ograniczenia wpływu jakości produktu na możliwość jego zakupu zostały ustawione filtry przede wszystkim na stan produktu. Objęte analizą zostały produkty nowe, używane, po zwrocie oraz powystawowe. Pozostałe, czyli uszkodzone i odnowione przez producenta albo sprzedawcę, zostały wykluczone. Kolejnym filtrem jest rodzaj oferty. Zostały wybrane tylko oferty „kup teraz”. Licytacje nie były brane pod uwagę, ponieważ nawet gdy wystawione są identyczne oferty przez tego samego sprzedawcę, cena końcowa poszczególnej jednostki może znacznie się różnić od pozostałych. Również zostały wykluczone ogłoszenia, gdyż to są oferty z Allegro Lokalnie, gdzie nie jest pokazana liczba sprzedanych jednostek potrzebna do dalszej analizy. Także do filtrów została dodana dostawa tylko z Polski, ponieważ takie produkty względnie łatwo można zwrócić, a także koszty dostawy są niskie lub zerowe w porównaniu do większości ofert zagranicznych. Ostatnim krokiem było sortowanie ofert po cenie od najniższej na potrzeby dalszej analizy.


Allegro ogranicza liczbę wyników na jedno zapytanie do 100 stron, co wymaga ręcznej zmiany zakresów cenowych i ponowne kopiowanie linku. Na każdej stronie znajduje się po 40 ofert, czyli maksymalnie 4000 ofert za sesję. Dzięki temu, że oferty zostały posortowane po cenie, wprowadzano zakresy cenowe i zmieniano je do tego momentu, gdy liczba stron była bliska i jednocześnie mniejsza od 100. Ponieważ URL zawierał w sobie numer strony, w łatwy sposób udało się zautomatyzować ten proces.

Na danym etapie ze stron z wynikami były wydobywane linki do ofert oraz aktualne ceny, a po uzyskaniu danych dla danego zakresu wyniki zapisywano do pliku csv w celu późniejszego połączenia go z pozostałymi plikami csv z danymi dla innych zakresów cenowych. Łącznie zostały wydobyte 122 422 oferty. Z pliku zbiorczego zostały usunięte duplikaty, które powstawały przede wszystkim z powodu ofert wyróżnionych¹²², w tym z Allegro lokalnie. Oferty z Allegro lokalnie zostały usunięte, ponieważ nie zawierają w sobie danych potrzebnych do dalszej analizy. Oferty sponsorowane również zostały skasowane w związku z ich obecnością wśród ofert niewyróżnionych.

¹²² Przykład linku do oferty sponsorowanej: https://allegro.pl/events/clicks?emission_unit_id=4e6aa9ba-8310-49e5-a1ad-dc0774e1ad6a&emission_id=6e365568-0a06-4440-99f7-29a05842b627&type=OFFER&ts=1629496488367&redirect=https%3A%2F%2Fallegro.pl%2Foferta%2Fdell-latitude-e7290-i5-7300u-4gb-ram-256ssd-w10-10511219272%3Fbi_s%3Dads%26bi_m%3Dlisting%253Adesktop%253Acategory%26bi_c%3DNTViZTEzYtgNzFhOC00NzlkLTg5ZDIYzQzMDUxMzIzNjIzAA%26bi_t%3Dape&placement=listing:desktop:category&sig=2b4a0623c0a9427e922201442c7d9d43

Ostatecznie zostały 106 484 oferty, których rozkład można zobaczyć na Rysunku 6. Z wykresu widać, że najwięcej ofert, ponad 37 tysięcy, znajduje się w przedziale od 1445 do 2445 zł. W związku z tym, że prędkość wydobywania danych jest poniżej 60 adresów URL na minutę, zdecydowano wyeliminować oferty o cenach poniżej 445 zł także z powodu występowania wśród nich ofert dotyczących produktów innych niż laptopy – akcesoria, nierелеwantne produkty, np. kawa, oraz powyżej 7600 zł. Po tym kroku liczba ofert wyniosła 94 101.

Rysunek 6. Rozkład cen ofert przed wydobywaniem danych z ofert



Źródło: opracowanie własne

Surowe dane wydobyte na danym etapie nie nadawały się do dalszej analizy. W tym celu zostały napisane funkcje do przetwarzania danych surowych, których kod zobrazowany jest na Rysunku 7. Funkcja `run_prices` służy do całego przetwarzania cen poszczególnych ofert, która zawiera w sobie funkcję `clean_price` umożliwiającą czyszczenie cen od znaków, które nie są ani cyframi, ani znakiem dziesiętnym, i później połączenie ceny w jeden ciąg znaków. Również przecinek dziesiętny został zastąpiony przez kropkę, ponieważ Python uznaje za separator dziesiętny jedynie kropkę.

Rysunek 7. Fragment kodu zawierający funkcje do przetwarzania wydobytych danych

```
def run_prices(platform, url):
    platform = linki[platform]
    products = url.select(platform['products'])
    prices = [element.select(platform['price']) for element in products]
    prices = [clean_price(element[0].text) for element in prices]
    return prices

def clean_price(price):
    pattern = r'[\d\.]+'
    price = price.replace(',', '.').replace(' ', '').replace('\n', '').replace('\t', '')
    clean_price = re.findall(pattern, price)
    clean_price[0] = ''.join(clean_price)
    if clean_price:
        return float(clean_price[0])
    else:
        return np.nan

def run_links(platform, url):
    platform = linki[platform]
    products = url.select(platform['products'])
    links = [element.select(platform['link']) for element in products]
    links = [element[0].get('href') for element in links]
    return links
```

Źródło: opracowanie własne

Na Rysunku 8 zaprezentowano fragment kodu, który został wykorzystany do powyższej analizy. Pierwszy akapit zawiera parametry niezbędne do pobrania adresów URL ofert w kategorii Laptopy na platformie Allegro. Drugi akapit służy do wydobywania adresów URL oraz cen ofert, a także przetwarzania tych danych za pomocą powyższych funkcji. Allegro prosi rozwiązać reCAPTCHA po wykonaniu dużej liczby zapytań. Empirycznie znaleziono sposób na obejście tego. Program sprawdza tytuł strony i jeżeli zawiera on „Captcha”, to przerywa aktywną sesję, a następnie uruchamia nową. Drugą przeszkodą na tym etapie stanowiła CAPTCHA zaimplementowana przez Allegro, która przestawała się pojawiać dopiero po wielokrotnym jej rozwiązaniu. Pojawiała się ona rzadko w porównaniu do reCAPTCHA (jeden raz na 15-20 zapytań), natomiast jeżeli Allegro wyświetlało ją jeden raz, to kolejne pojawiały się raz na 3-4 adresy URL. Druga przeszkoda zakłócała cały proces automatyzacji, dlatego dany etap wydłużył się wielokrotnie od planowanego. Wymagała ona siedzenia przed komputerem i rozwiązywania. Poradzono z tą przeszkodą następująco: gdy pojawia się ona, program się zatrzymuje i czeka określony czas (na rysunku jest to 1000 sekund), aż się pojawi strona z zapytania. Trzeci fragment łączy listy danych w jedną tabelę, a następnie zapisuje do pliku csv.

Rysunek 8. Fragment kodu wspierającego analizę kategorii Allegro

```
prices = []
link = []
options = Options()
profile = webdriver.FirefoxProfile()
binary = FirefoxBinary('D:\\Firefox\\App\\Firefox64\\firefox.exe')
exec_path = 'D:/Firefox/geckodriver.exe'
driver = webdriver.Firefox(executable_path=exec_path, firefox_binary=binary, firefox_profile=profile, options=options)
pages = 40 + 1
page = 'https://allegro.pl/kategoria/laptopy-491?stan=nowe&stan=u%C5%BCywane&stan=po%20zwrocie&'
page = page + 'stan=powystawowe&offerTypeBuyNow=1&dostawa-z-polski=tak&order=p&price_from=8201&p='

for i in range(1, pages):
    page_get = page + str(i)
    driver.get(page_get)
    if EC.title_contains('Captcha'):
        driver.close()
        driver = webdriver.Firefox(executable_path=exec_path, firefox_binary=binary, firefox_profile=profile, options=options)
        driver.get(page)
    if driver.title == 'allegro.pl':
        timeout = 1000
        WebDriverWait(driver, timeout).until(EC.title_contains('Allegro'))
        driver.get(page)
        strona = BeautifulSoup(driver.page_source, 'lxml')
        prices.extend(run_prices('allegro', strona))
        link.extend(run_links('allegro', strona))
    driver.quit()

all_oferty = pd.DataFrame()
all_oferty['link'] = link
all_oferty['price'] = prices
current_time = datetime.datetime.now()
teraz = str(current_time.hour) + '_' + str(current_time.minute)
all_oferty.to_csv('lista_' + teraz + '.csv')
```

Źródło: opracowanie własne

2.2.4. Wydobywanie opisów, cen, liczb kupujących oraz zakupionych jednostek towarów na poszczególnych ofertach

Ostatnim etapem związanym z pobieraniem danych bezpośrednio z witryny Allegro było wyciąganie elementów, takich jak opis, cena, liczba kupujących oraz zakupionych jednostek produktu, z pojedynczych ofert. W związku z tym, że liczba adresów URL na tym etapie wyniosła ponad 94 tysiące, etap ten był najbardziej praco- oraz czasochłonny. Zakłócanie programu przez CAPTCHA na danym etapie było bardziej dotkliwe niż poprzednio.

Z analizy zostały wyłączone oferty, na których nie sprzedano żadnej jednostki produktu, aby wykluczyć świeżo wystawione oferty. Wadą takiego podejścia jest brak obserwacji, gdzie brak sprzedanych jednostek może wiązać się z negatywnym wydźwiękiem opisu oferty.

Rysunek 9 przedstawia funkcje wspomagające proces przetwarzania wyekstrahowanych danych. Funkcja `run_price` służy do przekształcenia elementu HTML strony zawierającego cenę. Na potrzeby przetwarzania liczby sprzedanych jednostek użyto funkcji `run_buy`, która

najpierw szuka obecności sprzedanych jednostek. Jeśli nie znajduje, to zwraca 0. W przeciwnym razie przekształca najpierw element na listę mniejszych elementów, a następnie wydobywa liczbę kupujących oraz zakupionych jednostek. Jeżeli jednak zostały sprzedane wszystkie jednostki z oferty, liczba sprzedanych jednostek jest równa liczbie kupujących, ponieważ po zakończeniu sprzedaży Allegro pokazuje tylko sprzedane jednostki. Do przetwarzania opisów powstała funkcja `run_spec`, która najpierw usuwa tagi HTML (np. `<p></p>`), a następnie eliminuje znaki niebędące literami alfabetu polskiego. Ostatnim krokiem jest przekształcenie wszystkich liter na małe, ponieważ słownik składa się ze słów pisanych małymi literami.

Główny program został zamieszczony na Rysunku 10. W pierwszym akapicie tworzone są puste listy do dalszego ich uzupełnienia danymi z ofert, a także przygotowany jest program do sterowania przeglądarką oraz sama przeglądarka. Drugi akapit jest identyczny z tym akapitem z poprzedniego etapu z wyjątkiem wykorzystanych funkcji i pominięciem ofert z brakiem sprzedaży. Ostatni akapit służy do zapisania danych do pliku csv. Z poniższego kodu zostały usunięte linijki, które zapisywały wyniki pośrednie na wypadek nieprzewidzianych błędów lub innych sytuacji niepożądanych.

Rysunek 9. Funkcje do przetwarzania wydobytych cen, sprzedanych jednostek oraz opisów

```
def run_price(url):
    price = (url.select('div._1svub>span:nth-child(1)'))[0].text+(url.select('span._qnmldr:nth-child(2)'))[0].text
    price = price[:-3].replace('.', '').replace(',', '')
    return float(price)
def run_buy(url):
    try:
        all = list((url.select('._1h7wt.mgn2_13._1vryf._1t7v4'))[0].text.split(' '))
        try:
            if url.select('h4.mp0t_ji')[0].text == 'Sprzedaż zakończona':
                person = all[1]
                item = all[1]
                return int(person), int(item)
        except:
            person = re.sub('[^0-9]', '', all[0])
            item = all[3]
            return int(person), int(item)
        except:
            return 0
def run_spec(url):
    specs = re.sub(re.compile('<.*?>', ''), str(url.select('._2d49e_5pK0q')))
    specs = re.sub(r'[\u0020\u0041-\u005A\u0061-\u007A\u00104-\u0017C\u00F3\u00D3]', r'', specs)
    specs = (re.sub(' +', ' ', specs)).lower().strip()
    return specs
```

Źródło: opracowanie własne

Rysunek 10. Fragment kodu wspierającego analizę ofert

```
links_only = pd.Series(open('links_only.csv', 'r').read().splitlines())
prices = []
persons = []
items = []
specs = []
options = Options()
profile = webdriver.FirefoxProfile()
binary = FirefoxBinary('C:\\Firefox\\App\\Firefox64\\firefox.exe')
exec_path = r'C:/Firefox/geckodriver.exe'
driver = webdriver.Firefox(executable_path=exec_path, firefox_binary=binary, firefox_profile=profile, options=options)

for index, page in enumerate(links_only, start=1):
    try:
        driver.get(page)
        if EC.title_contains('Captcha'):
            driver.close()
            driver = webdriver.Firefox(executable_path=exec_path, firefox_binary=binary, firefox_profile=profile, options=options)
            driver.get(page)
        if driver.title == 'allegro.pl':
            timeout = 1000
            WebDriverWait(driver, timeout).until(EC.title_contains('Allegro'))
            driver.get(page)
            strona = BeautifulSoup(driver.page_source, 'xml')
            if run_buy(strona) == 0:
                continue
            prices.append(run_price(strona))
            person, item = run_buy(strona)
            persons.append(person)
            items.append(item)
            specs.append(run_spec(strona))
    driver.quit()

all_oferty = pd.DataFrame()
all_oferty['prices'] = prices
all_oferty['persons'] = persons
all_oferty['items'] = items
all_oferty['specs'] = specs
current_time = datetime.datetime.now()
all_oferty.to_csv('lista_'+str(current_time.hour)+'_'+str(current_time.minute)+'_'+str(index)+'.csv')
```

Źródło: opracowanie własne

Do dalszej analizy zostały włączone dane z 4246 ofert. Tabela 6 pokazuje pięć pierwszych i pięć ostatnich obserwacji z tabeli wynikowej. Znajdują się w niej ceny ofert, liczby sprzedanych jednostek oraz osób kupujących, a także opisy składające się wyłącznie ze słów pisanych małą literą, bez znaków interpunkcyjnych i liczb.

Tabela 6. Wydobyte dane z ofert

Cena	Osoby	Jednostki	Opis
449	11	13	acer r chromebook najważniejsze cechy oferowan...
449	6	6	lenovo yoga e chromebook najważniejsze cechy o...
449	1	1	lenovo chromebook n najważniejsze cechy ofero...
499	6	6	przedmiotem sprzedaży jest biznesowy laptop de...
449	1	1	dłaczego warto kupić ten model właśnie u nas l...
...	...	...	...
3989	1	1	laptop lenovo ideapad iil procesor intel core ...
2632	1	1	outlet apple macbook air procesor intel core i...
4099	5	7	laptop asus tuf gaming fxdtht fhd ryzen hgbg...
4099	4	5	hp pavilion gaming z tym laptopem wykosisz prz...
4099	2	2	fabrycznie nowy laptop lenovo ideapad lirr ga...

Źródło: opracowanie własne

2.3. Analiza wydźwięku emocjonalnego opisów ofert

Ostatnim etapem przed analizą regresji jest analiza wydźwięku emocjonalnego słów znajdujących się w opisach ofert na platformie handlowej Allegro. Przeprowadzono ją posługując się metodą słownikową z podejścia leksykalnego.

Analiza wydźwięku emocjonalnego jest metodą przetwarzania języka naturalnego, a zatem proces analizy można przeprowadzić według ogólnej kolejności operacji dla metod NLP. Analiza sentymentalna zaczyna się od tokenizacji tekstów¹²³. Polega ona na podziale tekstów bądź zdań na osobne słowa, mogą to też być części słów. Kolejnym krokiem analizy wydźwięku jest lematyzacja, czyli sprowadzenie słów do formy podstawowej. W związku z tym, że stworzony podczas pisania pracy słownik zawiera wszystkie możliwe formy słów, ten krok został pominięty. Przetwarzanie języka naturalnego również może wymagać rozpoznawania części mowy, jednak w danym przypadku nie jest to konieczne.

Ostatnią operacją w analizie wydźwięku będzie wyszukanie słów w słowniku i przyrost każdej zmiennej dla danej obserwacji w tabeli docelowej o wartość tej zmiennej ze słownika. Na przykład, jeśli opis składa się z trzech słów – „pięknymi”, „aktywnymi” oraz „agentami” („pięknymi aktywnymi agentami”), a w słowniku znajdują się tylko „aktywnymi” i „agentami”, to dla tej obserwacji zmienne będą miały wartości takie jak w Tabeli 7. Poniższe wartości są zaokrąglone do dwóch znaków po separatorze dziesiętnym, w rzeczywistości te liczby mają po 7 znaków w części dziesiętnej. Poza zmiennymi z Tabeli 7 w zbiorze danych również znajdują się zmienne z poprzednich części pracy.

Tabela 7. Wartości zmiennych dla sztucznie stworzonej obserwacji

	Word	Happiness	Anger	Sadness	Fear	Disgust	Happiness_dist	Anger_dist	Sadness_dist	Fear_dist	Disgust_dist	Neutral_dist
	aktywnymi	4.85	1.92	1.65	1.88	1.58	3.47	7.12	7.32	7.15	7.39	4.67
	agentami	1.62	2.58	1.50	2.81	2.35	6.80	5.96	6.98	5.48	6.19	3.69
Suma		6.46	4.50	3.15	4.69	3.92	10.27	13.09	14.30	12.64	13.57	8.36

Źródło: opracowanie własne

¹²³ <http://www.if.pw.edu.pl/~julas/TEXT/pliki/TEXT4.pdf>, s.19

Rysunek 11 obrazuje kod, który został wykorzystany do analizy wydźwięku emocjonalnego opisów ofert na Allegro. Najpierw zostały zaimportowane dane z pliku csv zawierającego opisy ofert, a także inne parametry tych ofert. Następnie utworzono 13 pustych list do uzupełniania ich w trakcie analizy. Drugi akapit to sama analiza sentymentu. Każdy opis jest dzielony na osobne słowa, czyli powstaje lista zawierająca wszystkie słowa z opisu. Następnie każde słowo poszukiwane w słowniku i, jeśli zostaje odnalezione, zmienne zawierające oceny emocji w danej obserwacji zostają powiększone o wartości tych zmiennych dla danego słowa. Proces ten trwa, dopóki nie zostaną sprawdzone wszystkie słowa. W przypadku braku słowa w słowniku funkcja do poszukiwania zwraca błąd i przyrost zmiennych nie następuje.

Gdy słowo zostało znalezione w słowniku, zmienna `reg_words` dla danej obserwacji wzrasta o jeden, czyli jest to zmienna pokazująca liczbę znalezionych słów z opisu oferty w słowniku. Po analizie opisu zostaje również zliczona liczba wszystkich słów w tekście, która jest przechowywana w zmiennej `all_words`. Po zakończeniu całego procesu analizy sentymentu zmienne zostają dodane do zbioru danych jako kolumny, a następnie zapisane do pliku csv. Jest to widoczne w ostatnim, trzecim, akapicie programu z Rysunku 11.

Rysunek 11. Fragment kodu programu do wykonania analizy wydźwięku emocjonalnego

```
oferty = pd.read_csv('full.csv', sep=';')
reg_words, all_words, hap, ang, sad, fea, dis, hap_d, ang_d, sad_d, fea_d, dis_d, neu_d = ([0] * 4246 for i in range(13))

for index, opis in enumerate(oferty['specs']):
    slowa = opis.split(' ')
    for slowo in slowa:
        try:
            match = slownik.index([slownik['Word'] == slowo])[0]
            hap[index] += slownik['Happiness'][match]
            ang[index] += slownik['Anger'][match]
            sad[index] += slownik['Sadness'][match]
            fea[index] += slownik['Fear'][match]
            dis[index] += slownik['Disgust'][match]
            hap_d[index] += slownik['Happiness_dist'][match]
            ang_d[index] += slownik['Anger_dist'][match]
            sad_d[index] += slownik['Sadness_dist'][match]
            fea_d[index] += slownik['Fear_dist'][match]
            dis_d[index] += slownik['Disgust_dist'][match]
            neu_d[index] += slownik['Neutral_dist'][match]
            reg_words[index] += 1
        except:
            pass
    all_words[index] = len(slowa)

dane_regr = pd.DataFrame()
dane_regr['reg_words'] = reg_words
dane_regr['all_words'] = all_words
dane_regr['persons'] = oferty['persons']
dane_regr['Happiness'] = hap
dane_regr['Anger'] = ang
dane_regr['Sadness'] = sad
dane_regr['Fear'] = fea
dane_regr['Disgust'] = dis
dane_regr['Happiness_dist'] = hap_d
dane_regr['Anger_dist'] = ang_d
dane_regr['Sadness_dist'] = sad_d
dane_regr['Fear_dist'] = fea_d
dane_regr['Disgust_dist'] = dis_d
dane_regr['Neutral_dist'] = neu_d
dane_regr['sales'] = oferty['sales']
dane_regr.to_csv('dane_regr.csv')
```

Źródło: opracowanie własne

Dane są gotowe do przeprowadzenia analizy regresji. Niemniej jednak na potrzeby analizy wprowadzone zostały zmiany. O tych zmianach zostało napisane w Rozdziale III.

Rozdział III. Analiza regresji na danych z analizy wydźwięku emocjonalnego

3.1. Opis zmiennych

Ostateczny zbiór danych łączy w sobie zarówno parametry ofert, jak i wyniki analizy sentymentu opisów tych ofert. Na podstawie niektórych zmiennych powstały dodatkowe zmienne, których celem jest potencjalnie wyższy poziom wyjaśnienia zmiennej zależnej za pomocą zmiennych niezależnych modelu. Zbiór zawiera 4246 obserwacji oraz 18 zmiennych, w tym jedną zmienną objaśnianą.


Na początku ze zbioru została usunięta jedna obserwacja, gdzie opis oferty składał się z 8 słów, żadne słowo nie zostało odnalezione w słowniku, a zatem brak jest wartości zmiennych dotyczących wydźwięku emocjonalnego. Po tym kroku w zbiorze danych zostało 4245 obserwacji. Składa się on z następujących zmiennych:


1. **Sales** – wartość sprzedaży danej oferty w złotych. Zmienna powstała po wymnożeniu aktualnej ceny przez liczbę zakupionych sztuk. Jest to zmienna zależna modelu.
2. **Reg_words** – liczba odnalezionych w słowniku słów z opisu oferty.
3. **All_words** – całkowita liczba słów w opisie oferty.
4. **Percent** – procent odnalezionych w słowniku słów z opisu oferty. Zmienna powstała poprzez dzielenie `reg_words` przez `all_words`.
5. **Persons** – aktualna (na moment pozyskiwania danych) osób, która dokonała zakupu produktów na danej ofercie.
6. **Prices** – aktualna (na moment wydobywania danych) cena jednostki produktu na danej ofercie wyrażona w złotych.
7. **Items** – aktualna (na moment pozyskiwania danych) liczba jednostek produktu zakupionych na danej ofercie.
8. **Happiness** – średnia ocen radości dla opisu danej oferty. Powstała poprzez dzielenie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, przez `reg_words`.
9. **Anger** – średnia ocen gniewu dla opisu danej oferty. Powstała poprzez dzielenie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, przez `reg_words`.
10. **Sadness** – średnia ocen smutku dla opisu danej oferty. Powstała poprzez dzielenie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, przez `reg_words`.

11. Fear – średnia ocen lęku dla opisu danej oferty. Powstała poprzez dzielenie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, przez `reg_words`.
12. Disgust – średnia ocen wstrętu dla opisu danej oferty. Powstała poprzez dzielenie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, przez `reg_words`.
13. Happiness_dist – odległość opisu danej oferty od centroidy skupienia radości. Powstała poprzez uśrednienie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, względem `reg_words`.
14. Anger_dist – odległość opisu danej oferty od centroidy skupienia gniewu. Powstała poprzez uśrednienie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, względem `reg_words`.
15. Sadness_dist – odległość opisu danej oferty od centroidy skupienia smutku. Powstała poprzez uśrednienie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, względem `reg_words`.
16. Fear_dist – odległość opisu danej oferty od centroidy skupienia lęku. Powstała poprzez uśrednienie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, względem `reg_words`.
17. Disgust_dist – odległość opisu danej oferty od centroidy skupienia wstrętu. Powstała poprzez uśrednienie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, względem `reg_words`.
18. Neutral_dist – odległość opisu danej oferty od centroidy skupienia neutralności. Powstała poprzez uśrednienie tejże zmiennej ze zbioru danych, powstałego po przeprowadzeniu analizy sentymentu, względem `reg_words`.

Pierwotne rozkłady zmiennych zostały zaprezentowane na Rysunku 12. Jak widać, większość zmiennych nie jest symetryczna, z czego 12 zmiennych ma prawostronną skośność, a w niektórych przypadkach zmienne mają obserwacje odstające oddalone od nieodstających, co może zaburzyć estymację. To oznacza, że wymagana jest normalizacja rozkładów.

Rysunek 12. Rozkłady zmiennych użytych do modelu





Źródło: opracowanie własne

Po wielu nieudanych próbach wyeliminowania obserwacji odstających ze zmiennych metodą przekształcenia Boxa-Coxa, wyznaczeniem wartości na podstawie kwartyli (i dalszym obcinaniem albo ograniczeniem wartości odstającej), ostatecznie zastosowano transformację logarytmiczną do zmiennej objaśnianej *sales*, a następnie zostały ręcznie dobrane warunki ograniczenia zmiennych w celu ich normalizacji: $6.5 < \text{sales} < 8.7$, czyli $665.14 < \text{sales} < 6002.91$

dla wartości niezlogarytmowanych, $\text{prices} < 4700$, $\text{persons} < 4$, $3.5 < \text{Happiness_dist} < 5.5$ oraz $\text{percent} < 24$. Po zastosowaniu tych ograniczeń liczba obserwacji spadła do 3174.

Tabela 8 pokazuje podstawowe statystyki zmiennych po wdrożeniu powyższych zmian. Zmiany te poprawiły rozkłady zmiennych, aczkolwiek w przypadku *persons* i *items* to nie zadziałało, ponieważ są to zmienne przyjmujące wyłącznie całkowite wartości.

Tabela 8. Podstawowe statystyki zmiennych do regresji

	reg_words	all_words	percent	persons	prices	items	Happiness	Anger	Sadness	Fear	Disgust	Happiness_dist	Anger_dist	Sadness_dist	Fear_dist	Disgust_dist	Neutral_dist	sales
mean	75.25	467.99	15.83	1.20	2166.03	1.25	3.41	1.81	1.79	2.05	1.49	4.65	6.68	6.71	6.46	6.96	3.63	2575.35
std	47.55	286.21	2.73	0.47	904.53	0.56	0.25	0.11	0.09	0.12	0.06	0.24	0.09	0.11	0.09	0.11	0.27	1187.00
min	3.00	22.00	4.79	1.00	449.10	1.00	2.36	1.25	1.49	1.47	1.24	3.58	6.27	6.24	5.95	6.40	2.16	670.00
25%	38.00	238.25	14.23	1.00	1420.50	1.00	3.26	1.76	1.73	1.97	1.45	4.48	6.63	6.63	6.41	6.89	3.49	1621.43
50%	68.00	434.00	16.03	1.00	2027.00	1.00	3.43	1.81	1.78	2.05	1.49	4.62	6.69	6.73	6.48	6.98	3.68	2439.00
75%	105.00	619.00	17.68	1.00	2849.00	1.00	3.58	1.87	1.84	2.12	1.52	4.79	6.74	6.79	6.53	7.04	3.81	3389.75
max	305.00	1831.00	23.58	3.00	4599.00	6.00	4.53	2.26	2.27	2.49	1.94	5.49	7.15	7.06	6.95	7.46	4.60	6000.00

Źródło: opracowanie własne

Dla wszystkich zmiennych przeprowadzono test Shapiro-Wilka na normalność rozkładu, gdzie hipoteza zerową jest normalność rozkładu. Ustalono poziom istotności na poziomie 5%. Z Tabeli 9 wynika, że p-value dla każdej ze zmiennych jest poniżej tej wartości, zatem hipoteza zerowa o normalności rozkładu jest odrzucona dla wszystkich zmiennych.

Tabela 9. wyniki testu Shapiro-Wilka

	reg_words	all_words	percent	persons	prices	items	Happiness	Anger	Sadness	Fear	Disgust	Happiness_dist	Anger_dist	Sadness_dist	Fear_dist	Disgust_dist	Neutral_dist	sales
Statystyka	0.95	0.93	0.99	0.46	0.97	0.50	0.98	0.98	0.97	0.99	0.95	0.98	0.96	0.96	0.96	0.96	0.93	0.96
P-value	1E-32	3E-35	8E-17	0	1E-25	0	7E-23	9E-19	6E-24	4E-14	1E-31	8E-21	2E-27	2E-27	2E-29	2E-29	3E-35	1E-28

Źródło: opracowanie własne

3.2. Przygotowanie zmiennych do regresji

Na potrzeby analizy regresji wybrano metodę najmniejszych kwadratów. Zanim rozpoczęto budowanie modelu, zmienne niezależne sprawdzono na występowanie korelacji.

Rysunek 13. Tablica korelacji zmiennych objaśniających

reg_words	1.00	0.98	0.32	0.02	0.13	0.03	0.29	0.01	0.34	0.10	-0.33	0.43	0.60	0.32	0.52	0.57	0.48
all_words	0.98	1.00	0.15	0.02	0.16	0.03	0.30	0.03	0.37	0.13	-0.28	0.40	0.57	0.27	0.50	0.56	0.44
percent	0.32	0.15	1.00	0.02	-0.04	0.01	0.09	-0.00	-0.00	-0.02	-0.25	0.26	0.29	0.37	0.28	0.26	0.29
persons	-0.02	0.02	0.02	1.00	-0.23	0.88	0.02	-0.03	0.06	-0.04	-0.06	0.05	0.07	0.00	0.07	0.06	0.07
prices	0.13	0.16	-0.04	-0.23	1.00	-0.26	-0.12	-0.07	-0.19	-0.18	-0.13	0.11	0.02	0.18	0.05	-0.04	0.07
items	0.03	0.03	0.01	0.88	-0.26	1.00	0.05	0.00	0.08	-0.00	-0.03	0.03	0.07	-0.01	0.07	0.07	0.06
Anger	0.29	0.30	0.09	0.02	-0.12	0.05	1.00	0.70	0.79	0.73	0.41	-0.10	0.29	0.03	0.41	0.60	-0.02
Sadness	-0.01	0.03	-0.00	-0.03	-0.07	0.00	0.70	1.00	0.53	0.58	0.55	-0.07	-0.17	0.05	0.24	0.34	-0.25
Fear	0.34	0.37	-0.00	0.06	-0.19	0.08	0.79	0.53	1.00	0.52	0.25	0.16	0.43	-0.23	0.52	0.67	0.14
Disgust	0.10	0.13	-0.02	-0.04	-0.18	-0.00	0.73	0.58	0.52	1.00	0.61	-0.27	0.02	-0.11	-0.07	0.25	-0.33
Happiness_dist	-0.33	-0.28	-0.25	-0.06	-0.13	-0.03	0.41	0.55	0.25	0.61	1.00	-0.78	-0.67	-0.64	-0.56	-0.41	-0.90
Anger_dist	0.43	0.40	0.26	0.05	0.11	0.03	-0.10	-0.07	0.16	-0.27	-0.78	1.00	0.77	0.68	0.81	0.71	0.88
Sadness_dist	0.60	0.57	0.29	0.07	0.02	0.07	0.29	-0.17	0.43	0.02	-0.67	0.77	1.00	0.55	0.83	0.85	0.88
Fear_dist	0.32	0.27	0.37	0.00	0.18	-0.01	0.03	0.05	-0.23	-0.11	-0.64	0.68	0.55	1.00	0.60	0.53	0.68
Disgust_dist	0.52	0.50	0.28	0.07	0.05	0.07	0.41	0.24	0.52	-0.07	-0.56	0.81	0.83	0.60	1.00	0.93	0.83
Neutral_dist	0.57	0.56	0.26	0.06	-0.04	0.07	0.60	0.34	0.67	0.25	-0.41	0.71	0.85	0.53	0.93	1.00	0.75
Happiness	0.48	0.44	0.29	0.07	0.07	0.06	-0.02	-0.25	0.14	-0.33	-0.90	0.88	0.88	0.68	0.83	0.75	1.00
	reg_words	all_words	percent	persons	prices	items	Anger	Sadness	Fear	Disgust	Happiness_dist	Anger_dist	Sadness_dist	Fear_dist	Disgust_dist	Neutral_dist	Happiness

Źródło: opracowanie własne

Jak widać na Rysunku 13, występuje silna korelacja (ponad $|0,7|$) pomiędzy:

- *reg_words* a *all_words* (0,98),
- *persons* a *items* (0,88),
- *Anger* a *Sadness* (0,7), *Fear* (0,79), *Disgust* (0,73),
- *Happiness* a *Happiness_dist* (-0,9), *Anger_dist*, *Sadness_dist* (0,88), *Disgust_dist* (0,83) oraz *Neutral_dist* (0,75),
- *Happiness_dist* a *Anger_dist* (-0,78),
- *Anger_dist* a *Sadness_dist* (0,77), *Disgust_dist* (0,81), *Neutral_dist* (0,71),
- *Sadness_dist* a *Disgust_dist* (0,83), *Neutral_dist* (0,85),
- *Disgust_dist* a *Neutral_dist* (0,93).

Aby wybrać, które zmienne usunąć z modelu, obliczono współczynniki inflacji wariancji (VIF) dla każdego predyktora. Tabela 10 przedstawia wyniki tych współczynników, na podstawie których zostaną usunięte skorelowane zmienne. Przyjmuje się, że wartość $VIF \leq 10$ jest dopuszczalna. Wartości powyżej świadczą o występowaniu współliniowości dla danej zmiennej. Zatem należy usuwać zmienne o wyższej wartości VIF. 9 zmiennych, które nie są włączone do modelu, zostały pogrubione w Tabeli 10. To oznacza, że początkowy model będzie zawierał 8 zmiennych niezależnych.

Tabela 10. Współczynnik inflacji wariancji dla zmiennych objaśniających

	VIF		VIF		VIF
		Anger	262.27	reg_words	64.85
Sadness_dist	379.49	Sadness	230.50	all_words	61.00
Disgust_dist	372.54	Anger_dist	217.99	items	4.39
Happiness_dist	319.11	Fear_dist	162.56	persons	4.33
Fear	283.95	Happiness	162.49	percent	3.23
Neutral_dist	267.70	Disgust	101.70	prices	1.37

Źródło: opracowanie własne

3.3. Analiza regresji

Do estymacji modelu przyjęto poziom istotności 5%. Po wyeliminowaniu silnie skorelowanych zmiennych estymowany jest model 1 ze stałą przedstawiony w Tabeli 11. Uwzględnia on 8 zmiennych objaśniających (Sadness, Fear_dist, Happiness, Disgust, all_words, persons, percent, prices) oraz zmienną objaśnianą sales. Dany model wyjaśnia 85,7% (adj. R^2) zmienności sales. P-value statystyki F jest mniejsze od 5%, co wskazuje na to, że hipoteza zerowa o łącznej nieistotności zmiennych niezależnych jest odrzucona.

Z modelu 1 zostaje usunięta zmienna *Sadness*, ponieważ p-value statystyki t-studenta tej zmiennej wynosi $0,979 > 0,05$, czyli nie ma podstaw do odrzucenia hipotezy zerowej o nieistotności danej zmiennej w modelu na poziomie 5%.

Tabela 11. Model 1

Dep. Variable:		sales		R-squared:		0.858
Model:		OLS		Adj. R-squared:		0.857
Method:		Least Squares		F-statistic:		2382.
No. Observations:		3174		Prob (F-statistic):		0.00
Df Residuals:		3165		Log-Likelihood:		839.60
Df Model:		8		AIC:		-1661.
Covariance Type:		nonrobust		BIC:		-1607.
	coef	std err	t	P> t 	[0.025	0.975]
const	5.6605	0.288	19.646	0.000	5.096	6.225
all_words	8.65e-05	1.41e-05	6.122	0.000	5.88e-05	0.000
percent	-0.0024	0.001	-1.815	0.070	-0.005	0.000
persons	0.6044	0.007	83.327	0.000	0.590	0.619
prices	0.0005	4.07e-06	114.176	0.000	0.000	0.000
Sadness	-0.0012	0.046	-0.026	0.979	-0.092	0.089
Disgust	-0.0087	0.071	-0.122	0.903	-0.148	0.130
Fear_dist	0.0670	0.053	1.254	0.210	-0.038	0.172
Happiness	-0.0204	0.023	-0.904	0.366	-0.065	0.024

Źródło: opracowanie własne

Model 2 z Tabeli 12 wyjaśnia również 85,7% zmiennej *sales*. Hipoteza zerowa testu RESET (statystyka F) w tym modelu również zostaje odrzucona, ponieważ $0 < 0,05$. Usunięta zostaje zmienna *Disgust*, bo $0,878 > 0,05$, zatem nie ma podstaw do odrzucenia hipotezy zerowej o nieistotności zmiennej w modelu na poziomie 5%.

Tabela 12. Model 2

Dep. Variable:		sales		R-squared:		0.858
Model:		OLS		Adj. R-squared:		0.857
Method:		Least Squares		F-statistic:		2723.
No. Observations:		3174		Prob (F-statistic):		0.00
Df Residuals:		3166		Log-Likelihood:		839.60
Df Model:		7		AIC:		-1663.
Covariance Type:		nonrobust		BIC:		-1615.
	coef	std err	t	P> t 	[0.025	0.975]
const	5.6615	0.286	19.826	0.000	5.102	6.221
all_words	8.65e-05	1.41e-05	6.124	0.000	5.88e-05	0.000
percent	-0.0024	0.001	-1.815	0.070	-0.005	0.000
persons	0.6044	0.007	83.352	0.000	0.590	0.619
prices	0.0005	4.07e-06	114.204	0.000	0.000	0.000
Disgust	-0.0096	0.062	-0.154	0.878	-0.132	0.112
Fear_dist	0.0666	0.052	1.289	0.198	-0.035	0.168
Happiness	-0.0203	0.022	-0.919	0.358	-0.063	0.023

Źródło: opracowanie własne

Przedstawiony w Tabeli 13 model 3 wyjaśnia 85,7% zmiennej *sales*. Hipoteza zerowa testu RESET (statystyka F) w tym modelu zostaje odrzucona, ponieważ $0 < 0,05$. Najmniej istotna zmienna w tym modelu to *Happiness*, a ponieważ jest zmienną pożądaną, zostaje usunięta inna zmienna. *Fear_dist*, której p-value dla testu t-studenta jest drugie najwyższe, nie jest istotna w modelu: $0,197 > 0,05$, zatem nie ma podstaw do odrzucenia hipotezy zerowej o nieistotności zmiennej w modelu na poziomie 5%.

Tabela 13. Model 3

Dep. Variable:	sales		R-squared:	0.858		
Model:	OLS		Adj. R-squared:	0.857		
Method:	Least Squares		F-statistic:	3178.		
No. Observations:	3174		Prob (F-statistic):	0.00		
Df Residuals:	3167		Log-Likelihood:	839.59		
Df Model:	6		AIC:	-1665.		
Covariance Type:	nonrobust		BIC:	-1623.		
	coef	std err	t	P> t 	[0.025	0.975]
const	5.6539	0.281	20.109	0.000	5.103	6.205
all_words	8.567e-05	1.31e-05	6.563	0.000	6.01e-05	0.000
percent	-0.0024	0.001	-1.817	0.069	-0.005	0.000
persons	0.6045	0.007	83.569	0.000	0.590	0.619
prices	0.0005	3.9e-06	119.169	0.000	0.000	0.000
Fear_dist	0.0647	0.050	1.290	0.197	-0.034	0.163
Happiness	-0.0186	0.019	-0.966	0.334	-0.056	0.019

Źródło: opracowanie własne

Tabela 14 pokazuje wyniki modelu 4, który wyjaśnia 85,7% zmiennej *sales*. Hipoteza zerowa testu RESET (statystyka F) dla tego modelu zostaje odrzucona, $0 < 0,05$. Najmniej istotną zmienną w tym modelu jest *Happiness*, a ponieważ jest zmienną pożądaną, zostaje usunięta inna zmienna. *Percent*, której p-value dla testu t-studenta jest drugie najwyższe, nie jest istotna w modelu: $0,125 > 0,05$, zatem nie ma podstaw do odrzucenia hipotezy zerowej o nieistotności zmiennej w modelu na poziomie 5%.

Tabela 14. Model 4

Dep. Variable:	sales		R-squared:	0.858		
Model:	OLS		Adj. R-squared:	0.857		
Method:	Least Squares		F-statistic:	3813.		
No. Observations:	3174		Prob (F-statistic):	0.00		
Df Residuals:	3168		Log-Likelihood:	838.75		
Df Model:	5		AIC:	-1666.		
Covariance Type:	nonrobust		BIC:	-1629.		
	coef	std err	t	P> t 	[0.025	0.975]
const	6.0110	0.049	122.916	0.000	5.915	6.107
all_words	8.421e-05	1.3e-05	6.475	0.000	5.87e-05	0.000
percent	-0.0019	0.001	-1.534	0.125	-0.004	0.001
persons	0.6044	0.007	83.550	0.000	0.590	0.619
prices	0.0005	3.81e-06	122.208	0.000	0.000	0.000
Happiness	-0.0032	0.015	-0.212	0.832	-0.033	0.026

Źródło: opracowanie własne

Tabela 15 pokazuje wyniki modelu 5, który wyjaśnia 85,7% zmiennej *sales*. Hipoteza zerowa testu RESET (statystyka F) dla tego modelu zostaje odrzucona, $0 < 0,05$. Najmniej

istotną zmienną w tym modelu jest *Happiness*, a w związku z tym, że jest zmienną pożądaną, zostaje usunięta inna zmienna. Z praktycznego punktu widzenia wyraz wolny nie ma sensu w tym modelu, gdyż w przypadku zerowych wartości wszystkich zmiennych niezależnych zmienna *sales* również powinna wynosić zero: nawet jeśli założyć, że oferta ma pusty opis, to bez zakupu co najmniej jednej jednostki wartość sprzedaży będzie zerowa. Po usunięciu stałej linia prosta będzie przechodziła przez punkt (0, 0), co jest naturalne dla wartości sprzedaży.

Tabela 15. Model 5

Dep. Variable:	sales			R-squared:	0.857		
Model:	OLS			Adj. R-squared:	0.857		
Method:	Least Squares			F-statistic:	4763.		
No. Observations:	3174			Prob (F-statistic):	0.00		
Df Residuals:	3169			Log-Likelihood:	837.57		
Df Model:	4			AIC:	-1665.		
Covariance Type:	nonrobust			BIC:	-1635.		
	coef	std err	t	P> t 	[0.025	0.975]	
const	5.9996	0.048	124.089	0.000	5.905	6.094	
all_words	8.36e-05	1.3e-05	6.429	0.000	5.81e-05	0.000	
persons	0.6046	0.007	83.580	0.000	0.590	0.619	
prices	0.0005	3.8e-06	122.628	0.000	0.000	0.000	
Happiness	-0.0092	0.015	-0.630	0.529	-0.038	0.019	

Źródło: opracowanie własne

W Tabeli 16 znajdują się wyniki dla modelu 6. W związku z tym, że został usunięty wyraz wolny, skorygowany R^2 może przyjmować wartości powyżej jedności, dlatego pakiet statystyczny automatycznie zamienił go na niescentrowany skorygowany współczynnik determinacji. Współczynnik ten przyjmuje wartości [0, 1], jednak ma inną interpretację. Poniższy model wyjaśnia 99,7% zmienności zmiennej *sales*. Wszystkie zmienne tego modelu są istotne, natomiast dla pewności warto sprawdzić wartości VIF.

Tabela 16. Model 6

Table 10: Model 9						
Dep. Variable:		sales		R-squared (uncentered):		0.997
Model:		OLS		Adj. R-squared (uncentered):		0.997
Method:		Least Squares		F-statistic:		2.348e+05
No. Observations:		3174		Prob (F-statistic):		0.00
Df Residuals:		3170		Log-Likelihood:		-1968.2
Df Model:		4		AIC:		3944.
Covariance Type:		nonrobust		BIC:		3969.
	coef	std err	t	P> t	[0.025	0.975]
all_words	-0.0005	2.95e-05	-16.297	0.000	-0.001	-0.000
persons	0.7311	0.017	42.186	0.000	0.697	0.765
prices	0.0006	9.05e-06	60.931	0.000	0.001	0.001
Happiness	1.7231	0.010	168.428	0.000	1.703	1.743

Źródło: opracowanie własne

VIF dla zmiennej *Happiness* jest powyżej 10, co wskazuje na silną współliniowość, jednak wartość ta może spaść poniżej 10 po usunięciu innej zmiennej, dlatego usunięta zostanie zmienna *persons*.

Tabela 17. Współczynnik inflacji wariancji dla zmiennych z modelu 6

Features	VIF
Happiness	19.12
persons	7.77
prices	7.07
all_words	4.1

Źródło: opracowanie własne

W Tabeli 18 znajdują się wyniki dla modelu 7. Niescentrowany skorygowany R^2 wskazuje na to, że model wyjaśnia 99,5% zmienności zmiennej *sales*. Wszystkie zmienne tego modelu są istotne, jednak może występować współliniowość, zatem sprawdzane są wartości VIF.

Tabela 18. Model 7

Dep. Variable:	sales		R-squared (uncentered):	0.995		
Model:	OLS		Adj. R-squared (uncentered):	0.995		
Method:	Least Squares		F-statistic:	2.002e+05		
Date:	Sun, 26 Sep 2021		Prob (F-statistic):	0.00		
Df Residuals:	3171		Log-Likelihood:	-2675.4		
Df Model:	3		AIC:	5357.		
Covariance Type:	nonrobust		BIC:	5375.		
	coef	std err	t	P> t 	[0.025	0.975]
all_words	-0.0005	3.68e-05	-14.263	0.000	-0.001	-0.000
prices	0.0005	1.1e-05	42.513	0.000	0.000	0.000
Happiness	2.0371	0.009	232.286	0.000	2.020	2.054

Źródło: opracowanie własne

Tabela 19 potwierdza brak występowania silnej współliniowości zmiennych w modelu 7. Wygenerowano również macierz korelacji, żeby sprawdzić wartości współczynników korelacji zmiennych niezależnych w modelu 7. Macierz korelacji została przedstawiona w Tabeli 20. Pomiędzy zmiennymi *Happiness* a *all_words* występuje nieznaczna korelacja, zatem zmienną można zostawić w modelu.

Tabela 19. Współczynnik inflacji wariancji dla zmiennych z modelu 7

Features	VIF
Happiness	9
prices	6.75
all_words	4.09

Źródło: opracowanie własne

Tabela 20. Macierz korelacji zmiennych z modelu 7

	all_words	prices	Happiness
all_words	1	0.157906	0.442612
prices	0.157906	1	0.066232
Happiness	0.442612	0.066232	1


Źródło: opracowanie własne

3.4. Sprawdzenie założeń regresji liniowej

1) Zależność liniowa pomiędzy predyktorami a zmienną *sales*:

Rysunek 14 pokazuje, że pomiędzy zmiennymi objaśniającymi a zmienną objaśnianej zachodzi zależność liniowa, choć nie jest ona idealna, zatem założenie o liniowej zależności jest spełnione.

Rysunek 14. Zależność pomiędzy zmiennymi niezależnymi a zmienną zależną z modelu 7




Źródło: opracowanie własne

2) Liczba obserwacji wynosi 3171, a liczba zmiennych objaśnianych – 3. Stosunek wynosi 1/1057, co świadczy o tym, że na jedną zmienną przypada 1057 obserwacji. Zakłada się, że w modelu powinno być około 15-20 obserwacji na jedną zmienną, czyli warunek ten jest spełniony.

3) Homoskedastyczność reszt modelu: na Rysunku 15 został pokazany rozkład wariancji reszt w modelu 7. Mimo, że wariancja nie jest w 100% stała, można przyjąć, że w modelu występuję homoskedastyczność reszt, zatem założenie jest spełnione.


Rysunek 15. Wariancja reszt w modelu 7




Źródło: opracowanie własne

4) Nie występuje autokorelacja reszt: ponieważ wyraz wolny został usunięty z modelu, test Durbin-Watsona może pokazywać nieprawidłową wartość, zatem wygenerowano wykresy ACF i PACF na Rysunku 16. Oba wykresy wskazują na silną dodatnią autokorelację pierwszego rzędu. To oznacza, że model nie spełnia danego założenia, co skutkuje tym, że estymator nie jest BLUE (best linear unbiased estimator), czyli jest obciążony oraz nie jest najefektywniejszy. Do modelu 7 przywrócono stałą i wykazano, że autokorelacja również występuje.

Rysunek 16. ACF i PACF dla reszt modelu 7 bez stałej i z nią






Źródło: opracowanie własne

5) Rozkład reszt jest normalny: p-value na poziomie $1,36e-28 < 0,05$ dla reszt w teście Andersona-Darlinga wykazał, że hipoteza zerowa o normalności rozkładu reszt została odrzucona. Z drugiej strony na Rysunku 17 zobrazowano rozkład reszt i można powiedzieć, że jest on zbliżony do normalnego, zatem założenie o normalności reszt jest spełnione.

Rysunek 17. Rozkład reszt w modelu 7



Źródło: opracowanie własne

6) Brak silnie skorelowanych zmiennych niezależnych: jak widać z Tabeli 20, zmienne w modelu 7 nie są silnie skorelowane, co oznacza, że założenie to zostało spełnione.

3.5. Interpretacja wyników modelu 7

W związku z tym, że zmienna objaśniana *sales* została zlogarytmowana, a zmienne objaśniające nie są logarytmami zmiennych pierwotnych, interpretacja współczynników zmiennych niezależnych wygląda inaczej. W takim przypadku interpretowane są semielastyczności. Współczynnik zmiennej (pomnożony razy 100%) mierzy o ile procent się

zmieni zmienna *sales*, gdy dana zmienna zmieni się o jedną jednostkę przy innych wartościach niezmiennionych (*ceteris paribus*).

- All_words: $-0,0005 * 100\% = -0,05\%$. Jeżeli opis oferty wzrośnie o jedno słowo, następuje przeciętny spadek wartości sprzedaży o 0,05% *ceteris paribus*.
- Prices: $0,0005 * 100\% = 0,05\%$. Wzrost ceny jednostki produktu oferty o jeden złoty powoduje przeciętny wzrost wartości sprzedaży o 0,05% *ceteris paribus*.
- Happiness: $2,0371 * 100\% = 203,71\%$. Wzrost średniej ocen radości dla opisu oferty o jedną jednostkę powoduje przeciętny wzrost wartości sprzedaży o 203,71% *ceteris paribus*.

Należy jednak pamiętać, że oszacowany model 7 jest spełniony tylko przy spełnieniu wszystkich następujących warunków: wartość sprzedaży znajduje się pomiędzy 665,14 zł a 6002,91 zł, cena jednostki produktu jest niższa od 4700 zł, liczba osób kupujących produkty na danej ofercie jest mniejsza od 4, odległość opisu danej oferty od centroidy skupienia radości znajduje się pomiędzy 3,5 a 5,5 jednostkami, a także procent znalezionych w słowniku słów z opisu oferty jest niższy od 24% wszystkich występujących w opisie słów.

Hipoteza zerowa niniejszej pracy zakładająca dodatni wpływ pozytywnego wydźwięku słów w opisie oferty na wartość sprzedaży została potwierdzona przy spełnieniu powyższych warunków.

Zakończenie

Mimo że hipoteza badawcza została potwierdzona, wiązało się to z wieloma ograniczeniami. To może być związane ze sposobem, w jaki wydobyto dane. Poza tym, na drodze stanęły różnego rodzaju przeszkody, które nie pozwoliły uzyskać bardziej różnorodnych danych, co negatywnie wpłynęło na wyniki regresji. Na przykład, nie było możliwości weryfikacji czasu wystawienia oferty, dlatego nie było wiadomo, z jakiego powodu na jednej ofercie zostało sprzedanych więcej jednostek produktu, a na innej – mniej.

Drugim możliwym wąskim gardłem jest słownik, który, po pierwsze, nie zawiera wszystkich słów, co nie pozwoliło ocenić całych opisów zawierających różne emocje. Tak samo słownik nie uwzględnia słów o tej samej pisowni, ale innym znaczeniu. Również nie było możliwe określenie kontekstu, od którego zależy sens zarówno samych słów, jak i całych zdań. Nawet gdy w zdaniu było zaprzeczenie, słownik nie pozwolił to wykryć, co mogło się wiązać z nieodpowiednią oceną emocjonalną tekstu.

W przyszłości zamierzono wykorzystać do analizy wydźwięku emocjonalnego metodę korpusową, która zawiera zarówno podobny do analizowanych danych rodzaj tekstów, jak i możliwy kontekst danych. Do analizy regresji również można zastosować inny model, który jest bardziej elastyczny wobec danych rzeczywistych i pozwala interpretować więcej aspektów zależności tak pomiędzy zmiennymi niezależnymi a zmienną zależną, jak i pomiędzy zmiennymi objaśniającymi.

Tak samo warto spróbować nawiązać współpracę z firmami, które udostępniłyby dane w zamian za analizę pozwalającą podnieść poziom obsługi klienta, co potencjalnie przyczyni się do zwiększenia zysków firmy.

Także można dodać do analizy wydźwięku emocjonalnego analizę pośrednią, która może wykazać ciekawą zależność pomiędzy badanymi w analizie sentymentu danymi a danymi innego rodzaju.

Bibliografia

1. Agarwal S. et al., BlinkDB: queries with bounded errors and bounded response times on very large data, Proceedings of the 8th ACM European Conference on Computer Systems, Association for Computing Machinery, 2013, s.29–42
2. Aggarwal, C., An introduction to social network data analytics, Social network data analytics, Springer, 2011, s.1–15
3. Agrawal D. et al., Challenges and opportunities with big data, A community white paper developed by leading researchers across the United States, 2012, s.34–43
4. Aho A., Sethi R., Ullman J., Compilers: principles, techniques, and tools, Addison-Wesley, 1986
5. Apache Software Foundation, Apache Hadoop YARN, 2021, <https://hadoop.apache.org/docs/current/hadoop-yarn/hadoop-yarn-site/YARN.html> [Dostęp: lipiec 2021]
6. Apache Software Foundation, Apache Hive TM, 2021, <https://hive.apache.org/> [Dostęp: lipiec 2021]
7. Apache Software Foundation, Apache Spark, 2021, <https://spark.apache.org/> [Dostęp: lipiec 2021]
8. Apache Software Foundation, Apache Storm, 2021, <https://storm.apache.org/> [Dostęp: lipiec 2021]
9. Apache Software Foundation, HDFS Architecture, 2021, <https://hadoop.apache.org/docs/r3.3.1/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html> [Dostęp: lipiec 2021]
10. Apache Software Foundation, Welcome to Apache Pig!, 2021, <https://pig.apache.org/> [Dostęp: lipiec 2021]
11. Aqlan A., Manjula B., Naik R., A Study of Sentiment Analysis: Concepts, Techniques, and Challenges, Proceedings of International Conference on Computational Intelligence and Data Engineering, 2019, s.147–162
12. Babić Rosario A., Sotgiu F., De Valck K., Bijmolt T., The Effect of Electronic Word of Mouth on Sales: A Meta-Analytic Review of Platform, Product, and Metric Factors, Journal of Marketing Research, vol. 53, nr 3, 2016, s.297–318
13. Bahia K., Joiner J., Satari A., 2020 Mobile Industry Impact Report: Sustainable Development Goals, GSM Association, 2020

14. Bengio Y., Ducharme R., Vincent P., Janvin C., A neural probabilistic language model, *The journal of machine learning research*, nr 3, 2003, s.1137–1155
15. Biltawi M. et al., Sentiment classification techniques for Arabic language: A survey, 7th International Conference on Information and Communication Systems, 2016, s.339–346
16. Brin S., Page L., The anatomy of a large-scale hypertextual web search engine, *Computer networks and ISDN systems*, vol. 30, nr 1–7, 1998, s.107–117
17. Carnegie Mellon Database Group, BlinkDB, 2021, <https://dbdb.io/db/blinkdb> [Dostęp: lipiec 2021]
18. Chakrabarti S., Data mining for hypertext: A tutorial survey, *ACM SIGKDD Explorations Newsletter*, vol. 1, nr 2, 2000, s.1–11
19. Chakrabarti S., Van den Berg M., Dom B., Focused crawling: a new approach to topic-specific Web resource discovery, *Computer networks*, vol. 31, nr 11–16, 1999, s.1623–1640
20. Chen M., Mao S., Liu Y., Big Data: A Survey. *Mobile Networks and Applications* nr 19, 2014, s.171–209
21. Cheng J., Druzdzel M., AIS-BN: An adaptive importance sampling algorithm for evidential reasoning in large Bayesian networks, *Journal of Artificial Intelligence Research*, vol. 13, 2000, s.155–188
22. Cheng L., Huang C., Exploring contextual factors from consumer reviews affecting movie sales: an opinion mining approach, *Electronic Commerce Research*, 2019
23. Chomsky N., On certain formal properties of grammars, *Information and control*, vol. 2, nr 2, 1959, s.137–167
24. Chomsky N., Three models for the description of language, *IRE Transactions on information theory*, vol. 2, nr 3, 1956, s.113–124
25. Chorowski J., Attention-based models for speech recognition, *Advances in Neural Information Processing Systems*, 2015, s.577–585
26. Clocksin W., Mellish C., *Programming in Prolog: Using the ISO Standard*, Springer, 2003
27. Collobert R., Weston J., A unified architecture for natural language processing: Deep neural networks with multitask learning, *Proceedings of the 25th international conference on Machine learning*, 2008, s.160–167
28. Dai A., Le Q., Semi-supervised sequence learning, *Advances in neural information processing systems*, nr 28, 2015, s.3079–3087

29. Dai W. et al., Translated learning: transfer learning across different feature spaces, Proceedings of the 21st International Conference on Neural Information Processing Systems, 2008, s.353–360
30. D'Andrea A., Ferri F., Grifoni P., Guzzo T., Approaches, Tools and Applications for Sentiment Analysis Implementation, International Journal of Computer Applications, vol. 125, nr 3, 2015, s.26–33
31. Dean J., Ghemawat S., MapReduce: simplified data processing on large clusters, Communications of the ACM, vol. 51, nr 1, 2008, s.107–113
32. DeWitt D., Gray J., Parallel database systems: the future of high performance database systems. Communications of the ACM, vol. 35, nr 6, 1992, s.85–98
33. Ding D. et al., Beyond audio and video retrieval: towards multimedia summarization, Proceedings of the 2nd ACM international conference on multimedia retrieval, 2012
34. El-Din D., Mokhtar H., Ismael O., Online paper review analysis, International Journal of Advanced Computer Science and Applications, vol. 6, nr 9, 2015, s.220–229
35. Elman J., Finding structure in time, Cognitive science, vol. 14, nr 2, 1990, s.179–211
36. ERCIM News, Special theme: Big Data, nr 89, 2012, <http://www.planet-data.eu/publications/ercim-news-special-theme-big-data.html> [Dostęp: lipiec 2021]
37. Gaber M., Zaslavsky A., Krishnaswamy S., Mining data streams: a review, ACM Sigmod Record, vol. 34, nr 2, 2005, s.18–26
38. Gantz J., Reinsel D., Extracting value from chaos, IDC iView, 2011, s.1–12
39. Garg M., Kim D., Turaga D., Prabhakaran B., Multimodal analysis of body sensor network data streams for real-time healthcare, Proceedings of the International Conference on Multimedia information retrieval, 2010, s. 469–478
40. Ghemawat S., Gobioff H., Leung S., The Google file system, ACM SIGOPS Operating Systems Review, vol. 37, nr 5, 2003, s.29–43
41. Goel A., Gautam J., Kumar S., Real time sentiment analysis of tweets using Naive Bayes, 2nd International Conference on Next Generation Computing Technologies, 2016, s.257–261
42. Hastie T., Tibshirani R., Friedman J., The Elements of Statistical Learning 2nd ed., Springer, 2009
43. Hatzivassiloglou V., McKeown K., Predicting the semantic orientation of adjectives, 35th annual meeting of the association for computational linguistics and 8th conference of the european chapter of the association for computational linguistics, 1997, s.174–181

44. Hazra T., Ghosh A., Sengupta A., Mukherjee N., Mitigating the adversities of social media through real time tweet extraction system, 2015 International Conference and Workshop on Computing and Communication, 2015, s.1–8
45. Hey T., Tansley S., Tolle K., The Fourth Paradigm: Data-Intensive Scientific Discovery, Microsoft Research, 2009
46. Hu M., Liu B., Mining and summarizing customer reviews, Proceedings of the tenth ACM SIGKDD international conference on Knowledge discovery and data mining, 2004, s.168–177
47. Hu W. et al., A survey on visual content-based video indexing and retrieval, IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), vol. 41, nr 6, 2011, s.797–819
48. Hussein D., A survey on sentiment analysis challenges, Journal of King Saud University-Engineering Sciences, vol. 30, nr 4, 2018, s.330–338
49. Hutchins W., The First Public Demonstration of Machine Translation: the Georgetown-IBM System, 7th January 1954, 2005, <https://web.archive.org/web/20210103023932/www.hutchinsweb.me.uk/GU-IBM-2005.pdf> [Dostęp: lipiec 2021]
50. International Data Corporation, Data Creation and Replication Will Grow at a Faster Rate than Installed Storage Capacity, According to the IDC Global DataSphere and StorageSphere Forecasts, 2021, <https://www.idc.com/getdoc.jsp?containerId=prUS47560321> [Dostęp: lipiec 2021]
51. Kim S., Hovy E., Determining the sentiment of opinions, Proceedings of the 20th International Conference on Computational Linguistics, 2004, s.1367–1373
52. Klein D., CS 294-5: Statistical Natural Language Processing, 2005
53. Kumar R., Raghavan P., Rajagopalan S., Tomkins A., Core algorithms in the CLEVER system, ACM Transactions on Internet Technology, vol. 6, nr 2, 2006, s.131–152
54. Laney D., 3D data management: controlling data volume, velocity and variety, META Group Research Note, 2001
55. LeCun Y., Bottou L., Bengio Y., Haffner P., Gradient-based learning applied to document recognition, Proceedings of the IEEE, vol. 86, nr 11, 1998, s.2278–2324
56. Levine J. et al., Lex & yacc, O'Reilly Media Inc., 1992
57. Li Y., Chen W., Wang Y., Zhang Z., Influence diffusion dynamics and influence maximization in social networks with friend and foe relationships, Proceedings of the sixth ACM international conference on Web search and data mining, 2013, s.657–666

58. Manning C., Raghavan P., Schuetze H., Introduction to Information Retrieval, Cambridge University Press, 2008
59. Manning C., Schutze H., Foundations of statistical natural language processing, MIT press, 1999
60. Mantyla M., Graziotin D., Kuutla M., The evolution of sentiment analysis—A review of research topics, venues, and top cited papers, Computer Science Review, vol. 27, 2018, s.16–32
61. Manyika J. et al., Big data: the next frontier for innovation, competition, and productivity, McKinsey Global Institute, 2011
62. Mayer-Schönberger V., Cukier K., Big Data: A Revolution that Will Transform how We Live, Work, and Think, 2013
63. Medhat W., Hassan A., Korashy H., Sentiment analysis algorithms and applications: A survey, Ain Shams engineering journal, vol. 5, nr 4, 2014, s.1093–1113
64. Merity S., Murphy T., Curran J., Accurate argumentative zoning with maximum entropy models, Proceedings of the 2009 Workshop on Text and Citation Analysis for Scholarly Digital Libraries, 2009, s.19–26
65. Mikolov T., Chen K., Corrado G., Dean J., Efficient estimation of word representations in vector space, ICLR, 2013
66. Mohammad S., Dunne C., Dorr B., Generating high-coverage semantic orientation lexicons from overtly marked words and a thesaurus, Proceedings of the 2009 conference on empirical methods in natural language processing, 2009, s.599–608
67. Nadkarni P., Ohno-Machado L., Chapman W., Natural language processing: an introduction, Journal of the American Medical Informatics Association, vol. 18, nr 5, 2011, s.544–551
68. Nature, Science in the petabyte era, vol. 455, nr 7209, 2008, <https://www.nature.com/nature/volumes/455/issues/7209> [Dostęp: lipiec 2021]
69. Pal S., Talwar V., Mitra P., Web mining in soft computing framework: Relevance, state of the art and future directions, IEEE Transactions on neural networks, vol. 13, nr 5, 2002, s.1163–1177
70. Parikh A., Tackstrom O., Das D., Uszkoreit J., A decomposable attention model for natural language inference, EMNLP, 2016
71. Park Y., Chang K., Individual and group behavior-based customer profile model for personalized product recommendation, Expert Systems with Applications, vol. 36, nr 2, 2009, s.1932–1939

72. Quinlan J., C4.5: Programs for Machine Learning, Morgan Kaufmann Publishers, 1993
73. Riegel M. et al., Nencki Affective Word List (NAWL): the cultural adaptation of the Berlin Affective Word List–Reloaded (BAWL-R) for Polish, Behavior Research Methods, vol. 47, nr 4, 2015, s.1222–1236
74. Scellato S., Noulas A., Mascolo C., Exploiting place features in link prediction on location-based social networks, Proceedings of the 17th ACM SIGKDD international conference on Knowledge discovery and data mining, 2011, s.1046–1054
75. Science, Dealing with Data, vol. 331, nr 6018, 2011, <https://science.sciencemag.org/content/331/6018> [Dostęp: lipiec 2021]
76. Socher R. et al., Recursive deep models for semantic compositionality over a sentiment treebank, Proceedings of the 2013 conference on empirical methods in natural language processing, 2013, s.1631–1642
77. Sun Y. et al., SIFRank: a new baseline for unsupervised keyphrase extraction based on pre-trained language model, IEEE Access, nr 8, 2020, s.10896–10906
78. Sutskever I., Vinyals O., Le Q., Sequence to sequence learning with neural networks, Advances in neural information processing systems, 2014, s.3104–3112
79. Tang J., Sun J., Wang C., Yang Z., Social influence analysis in large-scale networks, Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining, 2009, s.807–816
80. The R Foundation, What is R?, 2021, <https://www.r-project.org/about.html> [Dostęp: lipiec 2021]
81. Tung A., Rule-based Classification, Encyclopedia of Database Systems, Springer Publishing Company, 2009
82. Turovsky B., Found in translation: More accurate, fluent sentences in Google Translate, The Keyword Google Blog, 2016, <https://blog.google/products/translate/found-translation-more-accurate-fluent-sentences-google-translate/> [Dostęp: lipiec 2021]
83. UN Global Pulse, Big Data for Development: Challenges and Opportunities, 2012, <https://www.unglobalpulse.org/wp-content/uploads/2012/05/BigDataforDevelopment-UNGlobalPulseMay2012.pdf> [Dostęp: lipiec 2021]
84. Vaghela V., Jadav B., Analysis of Various Sentiment Classification Techniques, International Journal of Computer Applications, vol. 140, nr 3, 2016, s.22–27
85. Vavilapalli V. et al., Apache Hadoop YARN: yet another resource negotiator, Proceedings of the 4th annual Symposium on Cloud Computing, Association for Computing Machinery, artykuł nr 5, 2013, s.1–16

86. Versace C., Talking Big Data And Analytics With IBM, Forbes, 2014, <https://www.forbes.com/sites/chrisversace/2014/04/01/talking-big-data-and-analytics-with-ibm/> [Dostęp: lipiec 2021]
87. Verykios V. et al., State-of-the-art in privacy preserving data mining, ACM Sigmod Record vol. 33, nr 1, 2004, s.50–57
88. Vital Wave Consulting, Big Data, Big Impact: New Possibilities for International Development, World Economic Forum, 2012, http://www3.weforum.org/docs/WEF_TC_MFS_BigDataBigImpact_Briefing_2012.pdf [Dostęp: lipiec 2021]
89. Võ M. et al., The Berlin Affective Word List Reloaded (BAWL-R), Behavior Research Methods, vol. 41, nr 2, 2009, s.534–538
90. Walter T., Teradata past, present, and future, UCI ISG lecture series on scalable data management, 2009
91. Wan F., Ren F., The effect of firm marketing content on product sales: Evidence from a mobile social media platform, Journal of Electronic Commerce Research, nr 18, 2017, s.288–302
92. Wang M., Ni B., Hua X., Chua T., Assistive tagging: a survey of multimedia tagging with human-computer joint exploration, ACM Computing Surveys, vol. 44, nr 4, 2012
93. Weiss R., Zgorski L., PRESS RELEASE: Obama Administration Unveils "Big Data" Initiative: Announces \$200 Million in New R&D Investments, The White House, 2012, <https://obamawhitehouse.archives.gov/the-press-office/2015/11/19/release-obama-administration-unveils-big-data-initiative-announces-200> [Dostęp: lipiec 2021]
94. Wierzba M. et al., Basic Emotions in the Nencki Affective Word List (NAWL BE): New Method of Classifying Emotional Stimuli, PLOS ONE, vol. 10, nr 7, 2015, e0132305
95. Xu W., Ritter A., Grishman R., Gathering and generating paraphrases from twitter with application to normalization, Proceedings of the sixth workshop on building and using comparable corpora, 2013, s.121–128
96. Yang F., An implementation of naive bayes classifier, 2018 International Conference on Computational Science and Computational Intelligence, 2018, s.301–306
97. Yumusak S., Dogdu E., Kodaz H., Tagging accuracy analysis on part-of-speech taggers, Journal of Computer and Communications, vol. 2, nr 4, 2014, s.157–162

Spis tabel i rysunków

Tabela 1. Otwarte rozwiązania do analizy danych Big Data	10
Tabela 2. Formy słowa „człowiek” w słowniku Morfologik.....	30
Tabela 3. Formy słowa „akcja” w finalnej wersji słownika	30
Tabela 4. Kategorie pod względem liczby ofert	33
Tabela 5. Kategorie po wyeliminowaniu kategorii z podkategoriami	34
Tabela 6. Wydobyte dane z ofert	40
Tabela 7. Wartości zmiennych dla sztucznie stworzonej obserwacji	41
Tabela 8. Podstawowe statystyki zmiennych do regresji.....	48
Tabela 9. wyniki testu Shapiro-Wilka.....	48
Tabela 10. Współczynnik inflacji wariancji dla zmiennych objaśniających	50
Tabela 11. Model 1	51
Tabela 12. Model 2	52
Tabela 13. Model 3	53
Tabela 14. Model 4	54
Tabela 15. Model 5	55
Tabela 16. Model 6	56
Tabela 17. Współczynnik inflacji wariancji dla zmiennych z modelu 6	56
Tabela 18. Model 7	57
Tabela 19. Współczynnik inflacji wariancji dla zmiennych z modelu 7	57
Tabela 20. Macierz korelacji zmiennych z modelu 7	57
Rysunek 1. Techniki klasyfikacji sentymentów	23
Rysunek 2. Przykładowa część danych słownika NAWL	29
Rysunek 3, 4. Odpowiedzi Allegro na prośbę o udostępnienie danych do pracy magisterskiej	31
Rysunek 5. Fragment kodu wspierającego analizę kategorii Allegro	34
Rysunek 6. Rozkład cen ofert przed wydobywaniem danych z ofert	36
Rysunek 7. Fragment kodu zawierający funkcje do przetwarzania wydobytych danych	37
Rysunek 8. Fragment kodu wspierającego analizę kategorii Allegro	38
Rysunek 9. Funkcje do przetwarzania wydobytych cen, sprzedanych jednostek oraz opisów	39
Rysunek 10. Fragment kodu wspierającego analizę ofert.....	40
Rysunek 11. Fragment kodu programu do wykonania analizy wydźwięku emocjonalnego... ..	43
Rysunek 12. Rozkłady zmiennych użytych do modelu	46
Rysunek 13. Tablica korelacji zmiennych objaśniających	49
Rysunek 14. Zależność pomiędzy zmiennymi niezależnymi a zmienną zależną z modelu 7 .	58
Rysunek 15. Wariancja reszt w modelu 7	59
Rysunek 16. ACF i PACF dla reszt modelu 7 bez stałej i z nią.....	59
Rysunek 17. Rozkład reszt w modelu 7	60

Streszczenie

Niniejsza praca dotyczy zastosowania analizy regresji bazującej na wynikach z analizy sentymentu przeprowadzonej za pomocą metody słownikowej z podejścia leksykalnego w ramach przetwarzania języka naturalnego. Analiza regresji została przeprowadzona metodą najmniejszych kwadratów, aby sprawdzić występowanie zależności liniowej pomiędzy zmiennymi niezależnymi a wartością sprzedaży, która w danej pracy pełni funkcję zmiennej zależnej. Pierwszy rozdział pracy opisuje zastosowanie Big Data w różnych branżach, rozwój przetwarzania języka naturalnego oraz proces analizy sentymentu. Drugi rozdział skupia się na budowaniu słownika do analizy sentymentu, procesie wydobywania danych z platformy Allegro oraz przeprowadzeniu analizy wydźwięku emocjonalnego. W trzecim rozdziale przedstawiono opis zmiennych wykorzystanych do budowania modelu analizy regresji, przygotowanie tych zmiennych do analizy, samą analizę oraz wnioski wyciągnięte z wyników analizy. W pracy postawiono hipotezę badawczą o dodatnim wpływie pozytywnego wydźwięku emocjonalnego opisu oferty na wartość sprzedaży tej oferty.